基于控制障碍函数的安全强化学习方法复现

倒立摆与车辆跟随算例

作者：范金鹏 日期：2026 年 11 月 8 日

复现概述

复现范围 复现 Cheng 等的 RL-CBF 方法 [4]：将无模型强化学习、控制障碍函数（CBF）安全滤波 [1] 与高斯过程（GP）残差建模结合，在模型不确定时保障学习过程的安全并提高学习效率。通过原文的倒立摆和车辆跟随算例，检验三项结论：CBF 版本在学习全程不离开安全集；比对应的 TRPO、DDPG 基线学得更快；CBF 修正量随学习趋于零。

复现方法 代码来自作者公开仓库 `https://github.com/rcheng805/RL-CBF`。实验分为源码原样重跑与修改后运行两组：前者保留默认设置，由外部脚本补设种子并关闭渲染；后者调整模型、代码和实验设置。主要修改如下：

（1） **倒立摆：**模型方面，将论文中仅依赖状态的残差模型改为同时考虑控制输入，采用复合核 GP 和二阶锥 CBF 约束。代码方面，按论文恢复安全集与优化目标，修正 DDPG-CBF 的转移错位和动作范围错误，以及 TRPO-CBF 的过滤后重新采样和名义模型不一致问题。

（2） **车辆跟随：**模型与任务设置方面，调整论文的制动规则，使车距越小、制动越强，并在屏障中加入相对速度。代码方面，修正位置积分重复计入加速度、回放池状态覆盖、单样本批归一化导致 Actor 输出与状态无关的问题，并恢复按论文训练和使用补偿网络。

（3） **比较设置：**统一四种算法的环境、初态和训练量；训练参数的调整对同一算法及其 CBF 版本保持一致。环境调整、模型改进与代码修正分别说明。

主要结果

（1） **倒立摆：作者源码**。仅部分复现：TRPO-CBF 两个种子基本安全，第三个越界 332 次；DDPG-CBF 越界 37–127 次，CBF 修正量未消退。

（2） **倒立摆：修改后代码**。各算法在 3 个种子下分别训练 600 回合。TRPO-CBF 无越界，DDPG-CBF 仅在松弛量为正的第 7 回合越界一次；末 100 回合回报为 -3.5、-4.2，CBF 修正量由约 3.5 降至 $0.02\,\mathrm{N\cdot m}$，训练前后策略的表现与论文一致。

（3） **车辆跟随：作者源码**。复现了论文图 5 的主要现象：CBF 版本无碰撞，DDPG 训练末期仍频繁碰撞，DDPG-CBF 不收敛。

（4） **车辆跟随：修改后代码**。各算法在 3 个种子下分别训练 3×10^5 步。两种 CBF 版本均无碰撞，间距不低于 $2\,\mathrm{m}$；TRPO-CBF 在 1.1–1.4 万步达到回报阈值，修正量 RMS 由 1.4 降至 0.01；DDPG-CBF 出现补偿饱和，回报低于 DDPG。

总结与局限 修改后结果支持论文的安全性结论；CBF 作用消退在倒立摆两种 CBF 版本及车辆 TRPO-CBF 中成立，作者源码未能稳定复现。统一环境后，倒立摆 TRPO 与 CBF 版本的最终回报相当，车辆 DDPG 优于 DDPG-CBF，CBF 的主要收益在学习早期的安全。车辆跟随的环境、奖励与回合长度均有调整，回报不能与论文直接比较。

1 复现范围与实验设置

RL-CBF 利用粗略名义模型保障强化学习过程中的安全，执行输入为

$$u = u^{RL} + \bar{u}_\phi + u^{CBF}, \tag{1}$$

其中 u^{RL} 为 TRPO[11] 或 DDPG[7] 的策略输出，补偿网络 $\bar{u}_\phi$ 拟合历次 CBF 修正的累积作用（论文算法 1）；安全滤波器再利用 GP[10] 估计的残差均值与置信区间，求取最小修正 u^{CBF}。

倒立摆。 采用 Gym Pendulum-v0[3]，任务是在安全集 $|\theta| \le 1\,\mathrm{rad}$ 内稳定于竖直位置。真实质量与杆长为 $m = l = 1$，名义值均为 1.4，以此引入 40% 的参数误差；奖励惩罚摆角、角速度及控制力矩。除训练曲线外，还参照论文图 4 比较训练前后策略从相同初态出发的轨迹。

车辆跟随。 五辆车沿直线行驶，仅控制第 4 辆车的加速度输入，其余车辆按驾驶员模型跟踪目标车速并在近距时制动。真实阻尼、速度反馈及制动系数为 $k_d = 0.1$、$k_p = 4$、$k_b = 20$，名义值为 0、3.5、18。控制目标是在降低燃油与近距惩罚的同时，使第 4 辆车与前、后车的间距均不小于 2 m；碰撞与低于安全间距的越界分别统计。

两个算例的采样周期均为 0.05 s。修改后，各算法均采用种子 1、2、3；同一种子下共用初态序列，车辆算例还共用加速度噪声序列。主要设置见表 1。

表 1 两个算例的实验设置（修改后代码，四种算法共用）。与作者默认设置的对照见附录 E。

项目	倒立摆	车辆跟随
输入与初态	力矩 $\pm 15\,\mathrm{N\cdot m}$，角速度 $\pm 60\,\mathrm{rad/s}$；$\theta_0, \dot{\theta}_0 \sim U[-1, 1]$	输入 $\pm 100\,\mathrm{m/s^2}$；间距 $6 \pm 0.5\,\mathrm{m}$、速度 $30 \pm 1\,\mathrm{m/s}$ 均匀随机
训练量	每种算法、每个种子 600 回合，每回合 200 步	每种算法、每个种子 3×10^5 步，每回合至多 200 步
奖励与终止	原 Gym 二次型惩罚；达到回合时限截断	燃油与近距惩罚；碰撞立即终止并额外惩罚
环境噪声	沿用 Gym 确定性动力学	五辆车均加入高斯加速度噪声，标准差为 $1\,\mathrm{m/s^2}$

统一动力学、输入范围、初态与训练量，是为公平比较，属于实验配置调整。学习率、批量、探索噪声和观测处理按单种子预实验调整，以缓解训练振荡与探索不足 [5, 2]；同一算法及其 CBF 版本采用相同调整。

车辆跟随共用仿真器并统一噪声，以消除算法间的环境差异；延长回合、随机化初态，以覆盖更长的跟随过程与更多初态。碰撞后立即终止并额外惩罚，使其成为明确的失败事件；燃油项改按实际正加速度计算。这些调整改变了任务与奖励，因此回报仅作组内比较，两组之间仅对照碰撞和 2 m 越界。车辆 CBF 版本另用 400 步数据拟合初始 GP。完整参数、奖励公式与运行环境见附录 D、E。

2 复现方法与关键修改

模型与安全约束的调整见 2.1 节，代码实现问题及修正见 2.2 节。

2.1 残差建模与安全约束的调整

2.1.1 倒立摆

沿用原文记号，状态为 $s=(\theta,\dot{\theta})^\top$，$f(s)$ 和 $g(s)$ 分别表示名义漂移项和输入增益；u_t 为实际执行输入（对应原文动力学式 (1) 的 a_t），$a=u^{CBF}$ 专指安全修正。

输入相关残差与复合核 GP。 原文将未知残差写为 $d(s)$，但质量与杆长的 40% 偏差会同时改变漂移项和输入增益，真实输入增益约为名义值的 2.74 倍。省略当前时刻下标，残差写为

$$d(s,u)=s_{t+1}-f(s)-g(s)u=d_f(s)+d_g(s)u, \tag{2}$$

其中 d_f、d_g 分别表示漂移项和输入增益的模型误差。同一状态下，不同控制力矩对应不同的输入相关残差 $d_g(s)u$，而只以状态为输入的 GP 给出相同预测。为此，分别用先验独立的 GP 建模 d_f,d_g，采用 Umlauft 和 Hirche 的复合核构造 [13]

$$k\big((s,u),(s',u')\big)=k_f(s,s')+u\,k_g(s,s')\,u'. \tag{3}$$

后验均值 $\mu_d(s,u)=\mu_f(s)+\mu_g(s)u$，逐分量标准差 $\sigma_d(s,u)$ 可写为关于 u 的仿射函数的二范数。对仿射屏障函数 $h_i(s)=p_i^\top s+q_i$，论文式 (16) 需改为二阶锥约束

$$p_i^\top\big[f(s)+g(s)u+\mu_d(s,u)\big]+q_i-k_\delta|p_i|^\top\sigma_d(s,u)\geq(1-\eta)h_i(s)-\epsilon. \tag{4}$$

后验推导、固定超参数及求解方法见附录 A.1。

安全集与优化目标。 候选动作为 $u^{RL}+\bar{u}_\phi$，加入修正 $a=u^{CBF}$ 后得到执行输入 u。论文规定安全集 $|\theta|\leq 1$，目标为 $\|a\|_2+K_\epsilon\epsilon$；作者代码则采用斜向屏障（如 $|\theta|+0.05|\dot{\theta}|\leq 1$）和二次目标 $\frac{1}{2}a^2+\frac{1}{2}K_\epsilon\epsilon^2$，允许负松弛，并额外约束下一步角速度。修改后采用 $h_{1,2}=1\pm\theta$、$\epsilon\geq 0$，去掉速度约束，将目标恢复为 $|a|+K_\epsilon\epsilon$。按 $K_\epsilon\to\infty$ 的字典序求解：先求最小松弛 ϵ^*，再从满足该松弛量的输入中选取距候选动作最近的值。引入正松弛后，安全保证由原安全集 $\mathcal{C}$ 的前向不变性放宽为扩大集合 $\mathcal{C}_\epsilon$ 的前向不变性（论文引理 1）。

2.1.2 车辆跟随

对车 3–4 和车 4–5 两对相邻车辆，均按“前车减后车”定义位置差 Δp 与速度差 Δv。

驾驶员制动规则。 论文式 (27) 及源码采用 $-k_b\Delta p\,\mathbf{1}_{\{\Delta p\leq 6\}}$，制动随车距缩小而减弱，并在 6 m 处突变，不符合近距避碰所需的制动响应。改为 $-k_b\max(0,6-\Delta p)$，使制动随车距缩小而连续增强；车 5 对车 3 的制动阈值为 12 m、系数减半。名义模型同步调整，参数偏差不变。这属于任务设置变更，实现在 `car_simulator.py` 的 `driver_controls` 中。

车距约束的 CBF 构造。 车距裕量 $e=\Delta p-2$ 对加速度输入的相对阶为 2，而源码采用 8 个以位置为主的屏障 $h\approx\Delta p\pm\beta v-2$（$\beta=0.001$ 或 0.002）。修改后对前、后两对车辆构造

$$h=\dot{e}+\alpha e=\Delta v+\alpha(\Delta p-2),\qquad \alpha=2\ \mathrm{s}^{-1}, \tag{5}$$

并结合 GP 置信项施加 $h(s_{t+1})\geq(1-\eta)h(s_t)$。所得一维二次规划可闭式求解（`cbf.py`）：可行时投影到可行区间，不可行时最小化最大约束违反量并记录松弛（详见附录 A.2）。

2.2 关键实现问题与修正

表 2 汇总影响动力学建模、动作执行与策略学习的主要实现问题。源码片段、定量推导及逐文件对照见附录 A、B；训练配置调整见第 1 节。

表 2 主要实现问题与修正。两个算例中相同的问题合并列出。

涉及版本	问题及影响	修正方式
倒立摆 DDPG-CBF	状态先更新再记录，GP 标签及补偿网络输入错位一步；Actor 限幅仍为 ±2	保存每条转移 (s_t, u_t, s_{t+1})；内外层动作空间同步为 ±15
倒立摆 TRPO-CBF	GP 训练用 $m = l = 2$，预测用真实值 1，残差被错误叠加	训练与预测统一用名义值 1.4
两算例 TRPO-CBF	先过滤策略均值再采样，噪声可能破坏安全约束；旧策略均值含补偿与修正	先采样再补偿、过滤；策略更新使用原始动作及分布参数
车辆四种算法	先更新速度再积分位置，加速度对位移的贡献为正确值的 3 倍	改用更新前的速度积分位置
车辆 DDPG 类	回放池存入同一数组的视图，历史状态被覆盖；训练模式下单样本 BN 使 Actor 输出与状态无关	显式复制状态后存入回放池；移除 BN
两算例训练	时间截断被当作终止；TRPO 的 GAE 跨回合累积，线搜索不检查实际 KL	截断时用价值自举 [9]；逐回合计算 GAE[12]；KL 超限时拒绝更新
两算例 CBF 版本	GP 更新滞后；倒立摆 DDPG-CBF、车辆 TRPO-CBF 的补偿网络只在初期更新；车辆 DDPG-CBF 补偿输出固定为零	GP 每回合更新；补偿网络首轮输出为 0，随后每次迭代训练并使用；DDPG-CBF 回放池存 Actor 原始动作

3 结果对比与分析

3.1 倒立摆算例

若某回合中 $\max_t |\theta_t| > 1$，记为一次越界；“达标回合”指 20 回合滑动平均回报首次超过 -10 的回合。表 3 汇总两组结果，图 1 展示修改后训练曲线。

作者源码。 前 600 回合中，TRPO-CBF 种子 1、2 仅越界 1、9 次，种子 3 达 332 次；DDPG-CBF 越界 37–127 次且修正量未消退。前者与过滤后重新采样的机制一致，后者与 Actor 限幅及补偿冻结相吻合。作者基线约 68% 的初态已在安全集外，且力矩仅为 ±2，不能与 CBF 版本直接比较（附录图 C.3）。

修改后：安全性与学习速度。 TRPO-CBF 在三个种子共 1800 回合中无越界；DDPG-CBF 仅在种子 3 第 7 回合越界一次（最大摆角 1.103 rad，松弛量 0.096），正松弛均在前 9 回合。TRPO 基线前 100 回合均越界，第 300 回合后基本不再越界；DDPG 的越界持续至训练结束。TRPO-CBF、DDPG-CBF 分别在第 157–244、36–45 回合达标，均早于 TRPO 的第 264–268 回合，DDPG 未达标。统一环境后，TRPO 最终回报与 TRPO-CBF 相当（-3.33 对 -3.52），CBF 的收益主要在早期安全和更快达标。DDPG 仍会停在偏离竖直的角度，其训练不稳定也扩大了性能差距。

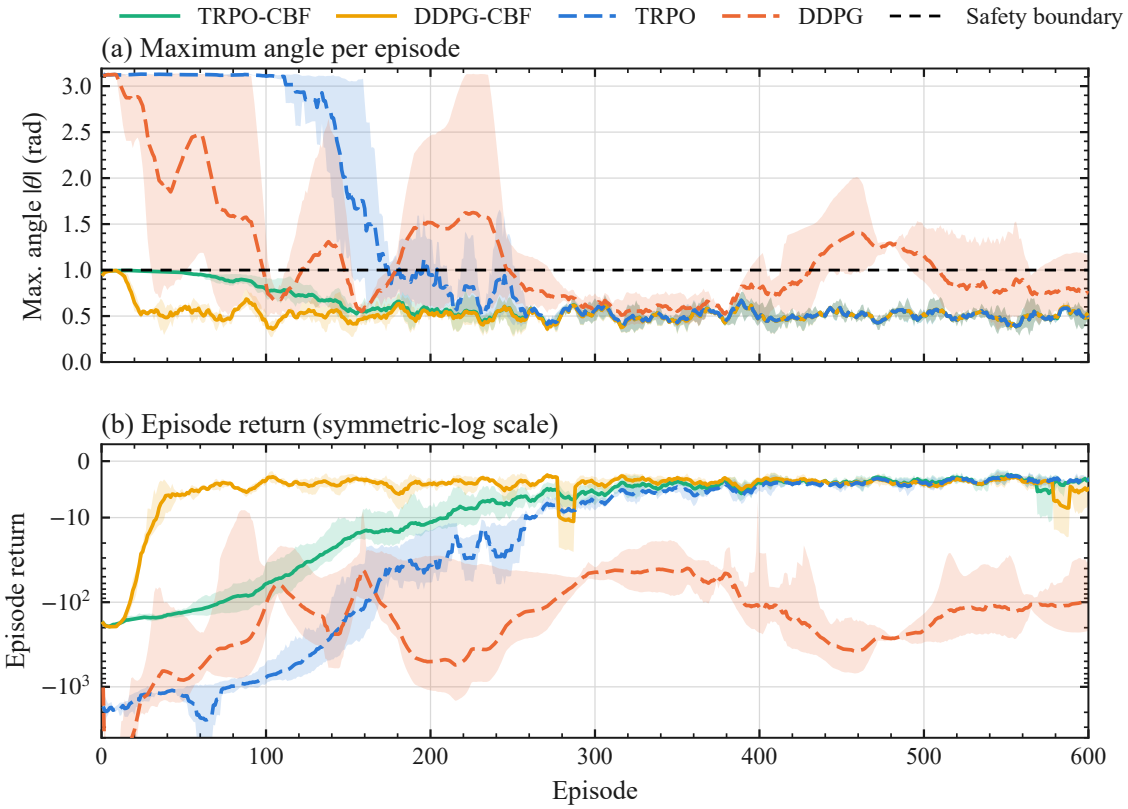


图 1 倒立摆训练结果（修改后代码，种子 1–3，各 600 回合）。(a) 每回合最大摆角；(b) 回合回报，纵轴采用对称对数刻度。先对每个种子的曲线作 10 回合滑动平均，再取 3 个种子的均值（粗线）及最小值到最大值的范围（阴影）。累计越界与修正量见附录图 C.1，各种子回报见图 C.2。

表 3 倒立摆训练结果汇总（前 600 回合）。回报为 3 个种子的均值 ± 样本标准差，修正量 RMS 取种子均值；越界数与达标回合按种子 1/2/3 列出。† 作者基线的力矩限幅为 ±2，初始摆角 $\theta_0 \in [-\pi, \pi]$，任务设置与其他版本不同，相关指标不宜直接比较。

算法	后 100 个回合回报	越界回合数 / 600	达标回合	修正量 RMS（N · m）前 10 → 后 100
作者源码，默认设置				
TRPO†	-1078.8 ± 147.2	600 / 600 / 600	未达标	—
DDPG†	-200.3 ± 29.6	534 / 545 / 546	未达标	—
TRPO-CBF	-69.7 ± 107.6	1 / 9 / 332	65 / 64 / 未达标	3.9 → 0.07
DDPG-CBF	-82.3 ± 17.2	127 / 67 / 37	未达标	7.7 → 3.5
修改后代码，统一环境				
TRPO	-3.33 ± 0.07	174 / 155 / 143	265 / 268 / 264	—
DDPG	-115.8 ± 54.5	217 / 209 / 295	未达标	—
TRPO-CBF	-3.52 ± 0.65	0 / 0 / 0	213 / 244 / 157	3.3 → 0.02
DDPG-CBF	-4.16 ± 1.25	0 / 0 / 1	41 / 36 / 45	3.7 → 0.01

CBF 修正量的消退。 TRPO-CBF、DDPG-CBF 的修正量 RMS 由前 10 回合的约 3.5 分别降至后 100 回合的 0.02、0.01 N · m，训练后较少依赖安全滤波（附录图 C.1）。

训练所得策略的闭环仿真。 参照论文图 4，重跑种子 1，从同一组 10 个随机初态以确定性动作各仿真 10 s（图 2）。初始控制器使用未训练策略、零补偿与 GP 先验，训练后则使用相应的策略、补偿网络与 GP 后验；评估期间均不更新 GP（协议见附录 D.1）。训练前依靠较大 CBF 力矩修正将摆角维持在 $|\theta| \approx 0.9$ 附近；训练后在 1–2 s 内回到竖直并保持稳定，评估期间 $u^{CBF} = 0$，与论文现象一致。

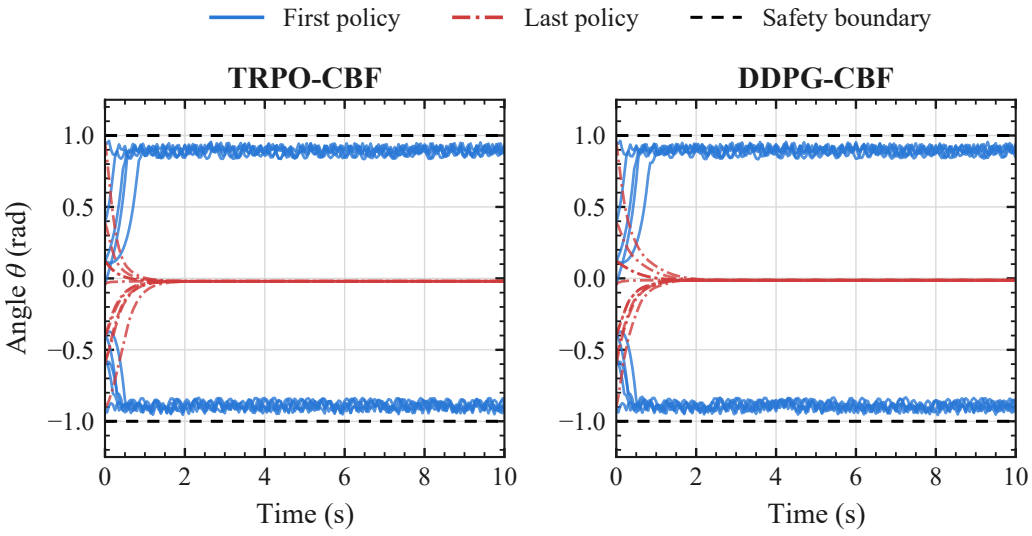


图 2 倒立摆训练前后策略的闭环摆角响应（种子 1，含补偿与安全滤波）。两种 CBF 版本从同一组 10 个初态（$\theta_0, \dot{\theta}_0 \sim U[-1, 1]$）以确定性动作各运行 10 s，GP 不在线更新。蓝色实线、红色点划线分别为训练前、训练后，黑色虚线为安全边界。

3.2 车辆跟随算例

定义最小间距为 $d = \min(p_3 - p_4, p_4 - p_5)$，回合内 $\min_t d \le 0$ 为碰撞，$\min_t d < 2$ 为越界。作者环境在碰撞后仍继续运行至回合结束，修改后则在检测到碰撞时立即终止回合。结果见表 4、图 3。

作者源码。 两种 CBF 版本在训练全程均无碰撞（附录图 C.4），但合计 12 回合的最小间距低于 2 m，越界幅度均小于 0.1 m。DDPG-CBF 仍未收敛，回报从约 -4.8×10^4 提高到 -2.9×10^4，CBF 修正量却随训练增大，控制器持续依赖安全滤波器。这与 Actor 输出不随状态变化、回放池数据被覆盖及补偿网络未启用的问题相吻合。DDPG 在训练末期仍频繁碰撞，与论文图 5 一致。TRPO 三个种子在前 600 回合分别碰撞 310、452、599 次，但在默认训练长度（22515 回合）的末期均不再碰撞，说明这一现象随观察区间而变化。各随机种子的详细结果见附录 C.2。

修改后：安全性与学习速度。 每种 CBF 版本在三个种子下共训练 9×10^5 步，个别回合虽出现正松弛或实际转移未满足 CBF 条件，但均无碰撞、无越界，最小车距为 2.33 m（附录 C.2）。DDPG 仅在前 8000 步碰撞；TRPO 种子 1、2 的碰撞持续至训练结束，种子 3 在 13.3 万步后不再碰撞。以 50 回合滑动平均回报首次超过 -5000 为达标标准，TRPO-CBF 需 1.1–1.4 万步，早于 DDPG 的 2.0–2.3 万步；TRPO 为 11.4、20.9 万步（种子 1 未达标），DDPG-CBF 仅种子 1 在 3.8 万步达标。TRPO-CBF 末 100 回合回报为 -740 ± 122，三个种子均较快达标；TRPO 仅种子 3 的最终回报与之相当。

表 4 车辆跟随训练结果汇总。回报为 3 个种子的均值 ± 样本标准差，修正量为种子平均 RMS（$\mathrm{m/s^2}$）；碰撞与越界按回合计数，依次列出种子 1/2/3。两组任务设置不同，回报仅作组内比较。

算法	末 100 个回合回报	碰撞数	越界数	末 100 个中的碰撞	修正量 RMS 前 10 → 末 100
作者源码，默认设置（每个回合 80 步）					
TRPO	-2156 ± 443	1247 / 825 / 7093	3634 / 3575 / 9824	0 / 0 / 0	—
DDPG	$(-3.2 \pm 4.9) \times 10^5$	462 / 688 / 878	623 / 804 / 927	95 / 64 / 84	—
TRPO-CBF	-2305 ± 1067	0 / 0 / 0	1 / 0 / 1	0 / 0 / 0	13.6 → 1.5
DDPG-CBF	-28937 ± 2359	0 / 0 / 0	0 / 10 / 0	0 / 0 / 0	21.7 → 29.5
修改后代码，统一环境（每个回合 200 步，3×10^5 步）					
TRPO	-7837 ± 10457	2564 / 1908 / 1432	2620 / 2099 / 1471	95 / 37 / 0	—
DDPG	-2586 ± 208	69 / 151 / 35	100 / 177 / 69	0 / 0 / 0	—
TRPO-CBF	-740 ± 122	0 / 0 / 0	0 / 0 / 0	0 / 0 / 0	1.38 → 0.01
DDPG-CBF	-5856 ± 3745	0 / 0 / 0	0 / 0 / 0	0 / 0 / 0	30.6 → 3.9

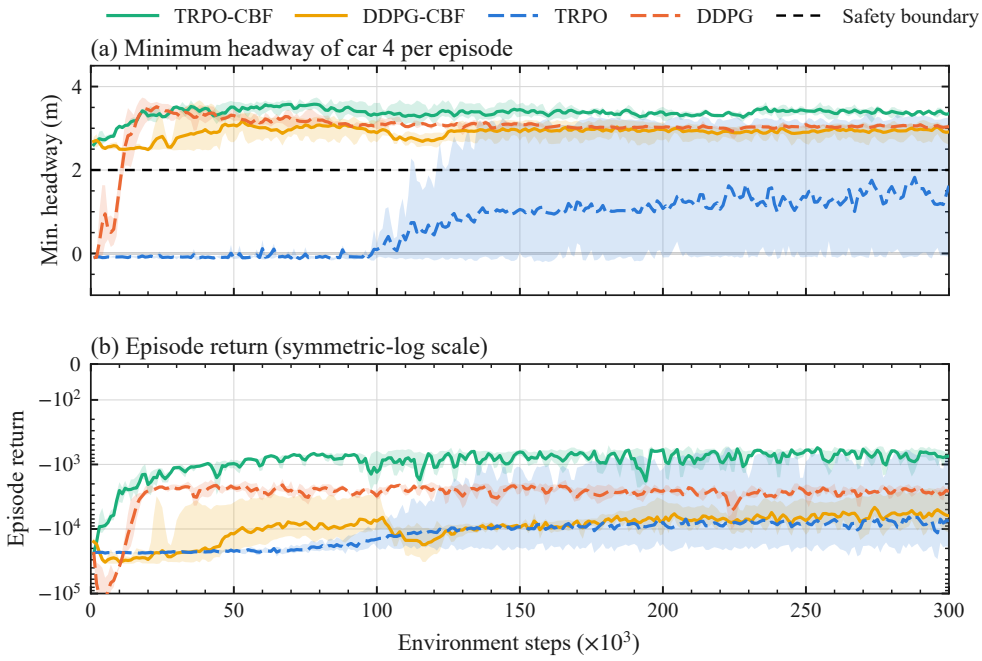


图 3 车辆跟随训练中的安全性与回报变化（修改后代码，种子 1–3，各 3×10^5 步）。(a) 每回合最小车距，虚线为 2 m 安全间距；(b) 回合回报，纵轴采用对称对数刻度。横轴为环境步数，平滑及种子汇总方式同图 1。累计碰撞、越界与修正量见附录图 C.5，各种子回报见图 C.6。

修正量消退与补偿饱和。 TRPO-CBF 的修正量 RMS 由 1.38 降至 $0.01\,\mathrm{m/s^2}$，补偿输出 RMS 增至约 $1.6\,\mathrm{m/s^2}$，表明补偿网络逐步承担了安全修正。DDPG-CBF 的修正量虽降至 $3.9\,\mathrm{m/s^2}$，补偿输出却接近饱和（RMS 为 92–98 $\mathrm{m/s^2}$），回报低于 DDPG。闭环仿真中，种子 1 的 Actor 与补偿输出均值为 -91.9、$93.1\,\mathrm{m/s^2}$，抵消后执行输入均值仅约 $1.2\,\mathrm{m/s^2}$。加性结构允许这种偏置；Actor 接近 tanh 饱和时，梯度可能减弱并限制学习。这一推断未做消融或梯度测量验证（附录 C.2）。

训练所得策略的闭环仿真。 使用各次训练最后保存的策略，在相同初态和噪声下以确定性动作仿真 10 s；CBF 版本保留补偿网络与安全滤波器，GP 经重新标定和 5 个预热回合拟合后固定。图 4 中，种子 1 的 TRPO-CBF、DDPG-CBF 与 DDPG 均随前车减速，最小车距为 3.1–3.3 m；TRPO 减速过多，在 7.0 s 被追尾。TRPO-CBF 与 DDPG 在三个种子中均无碰撞，前者评估期间的 CBF 均不介入。DDPG-CBF 种子 2、3 的 CBF 介入比例分别为 62%、55%，最小车距为 2.46、2.83 m，种子 3 的输入还明显振荡，安全仍依赖 CBF。TRPO 种子 2 虽未碰撞，末尾车距已降至 0.76 m。其余轨迹与指标见附录图 C.7、表 C.4，评估与动画说明见附录 D.2。

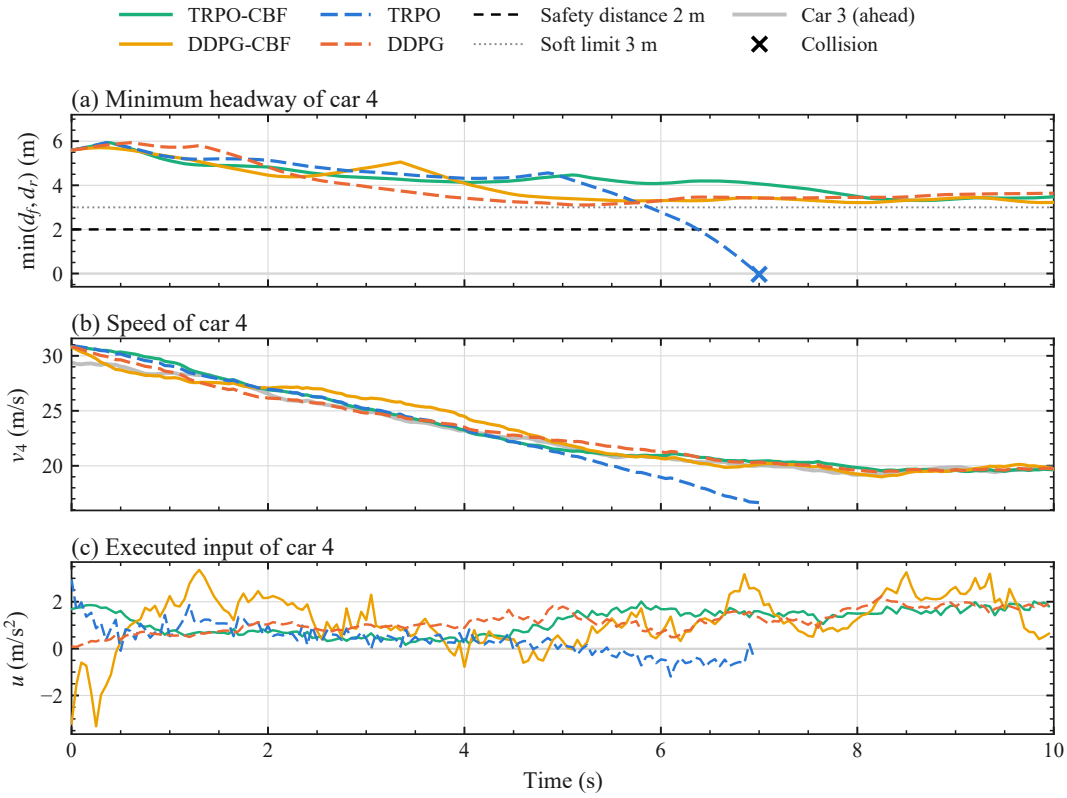


图 4 车辆跟随训练后策略的闭环响应（种子 1，确定性动作，10 s）。使用各算法最后保存的策略，初态与加速度噪声序列相同。(a) 第 4 辆车与前、后车的最小间距，虚线为 2 m 安全边界，点线为 3 m 软约束阈值，× 表示碰撞终止；(b) 第 4 辆车车速，灰线为前车车速，四种算法相同；(c) 执行输入，CBF 版本为策略输出、补偿输出与 CBF 修正之和。详细设置见附录 C.2。

4 复现总结与局限

修改后，倒立摆的学习速度与修正量消退、车辆 TRPO-CBF 的安全性与学习效率得到复现；倒立摆的一次早期越界和车辆 DDPG-CBF 的补偿饱和仍未解决。CBF 显著改善学习阶段的安全，最终回报并不总优于基线。

实验仅含三个种子，模型、实现及配置同时调整，尚未通过单项消融区分贡献 [6]；车辆回报仅限组内比较。GP 置信界尚未验证覆盖学习全过程，零越界属于实验观察。后续优先检验各项修改的贡献、GP 经验覆盖率及补偿网络的饱和抑制。