安全强化学习方法复现报告

参考文献与补充材料

作者：范金鹏 日期：2026 年 11 月 8 日

参考文献

[1] Aaron D. Ames et al. “Control Barrier Function Based Quadratic Programs for Safety Critical Systems”. In: *IEEE Transactions on Automatic Control* 62.8 (2017), pp. 3861–3876.

[2] Marcin Andrychowicz et al. “What Matters for On-Policy Deep Actor-Critic Methods? A Large-Scale Study”. In: *International Conference on Learning Representations*. 2021.

[3] Greg Brockman et al. *OpenAI Gym*. arXiv:1606.01540. 2016.

[4] Richard Cheng et al. “End-to-End Safe Reinforcement Learning through Barrier Functions for Safety-Critical Continuous Control Tasks”. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 33. 1. 2019, pp. 3387–3395. DOI: 10.1609/aaai.v33i01.33013387.

[5] Scott Fujimoto, Herke van Hoof, and David Meger. “Addressing Function Approximation Error in Actor-Critic Methods”. In: *Proceedings of the 35th International Conference on Machine Learning*. Vol. 80. PMLR. 2018, pp. 1587–1596.

[6] Peter Henderson et al. “Deep Reinforcement Learning That Matters”. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 32. 1. 2018.

[7] Timothy P. Lillicrap et al. “Continuous Control with Deep Reinforcement Learning”. In: *International Conference on Learning Representations*. 2016.

[8] Skander Moalla et al. “[Re] Reproducibility Study of Behavior Transformers”. In: *ReScience C* 9.2 (2023), #43. DOI: 10.5281/zenodo.8173757.

[9] Fabio Pardo et al. “Time Limits in Reinforcement Learning”. In: *Proceedings of the 35th International Conference on Machine Learning*. Vol. 80. PMLR. 2018, pp. 4045–4054.

[10] Carl Edward Rasmussen and Christopher K. I. Williams. *Gaussian Processes for Machine Learning*. MIT Press, 2006.

[11] John Schulman et al. “Trust Region Policy Optimization”. In: *Proceedings of the 32nd International Conference on Machine Learning*. Vol. 37. PMLR. 2015, pp. 1889–1897.

[12] John Schulman et al. “High-Dimensional Continuous Control Using Generalized Advantage Estimation”. In: *International Conference on Learning Representations*. 2016.

[13] Jonas Umlauft and Sandra Hirche. “Feedback Linearization Based on Gaussian Processes With Event-Triggered Online Learning”. In: *IEEE Transactions on Automatic Control* 65.10 (2020), pp. 4154–4169. DOI: 10.1109/TAC.2019.2958840.

附录 A 理论与模型补充推导

本附录补充正文第 2 节的模型推导与求解方法：先说明倒立摆残差的输入相关性、复合核 GP 后验及安全约束，再说明车辆跟随的位置积分与车距屏障。

A.1 倒立摆

沿用正文记号，$s=(\theta,\dot\theta)^\top$，$f(s)$、$g(s)$ 分别为名义漂移项和输入增益，u 为执行力矩，$a=u^{CBF}$ 为安全修正。真实质量、杆长记为 m,l，名义值记为 m_n,l_n；重力加速度用 $g_0=10\,\mathrm{m/s^2}$ 表示，以区别输入增益 $g(s)$。令 $c=(\Delta t^2,\Delta t)^\top$，Pendulum-v0 的离散动力学（论文式 (17)）可写为

$$s_{t+1}=s_t+\begin{pmatrix}\dot\theta_t\,\Delta t\\0\end{pmatrix}+\frac{3g_0}{2l}\sin\theta_t\,c+\frac{3}{ml^2}u_t\,c. \tag{A.1}$$

名义模型采用同一形式，将 m,l 替换为 m_n,l_n，因此 $g(s)=\frac{3}{m_nl_n^2}c$。仿真器的角速度限幅为 $\pm60\,\mathrm{rad/s}$；以下推导针对未触发该限幅的转移。

A.1.1 残差的输入相关性

GP 的训练标签为实际下一状态与名义预测之差：

$$y_t=s_{t+1}-f(s_t)-g(s_t)u_t=d_f(s_t)+d_g(s_t)u_t. \tag{A.2}$$

由式 (A.1) 与名义模型相减，得到

$$d_f(s)=\Big(\frac{3g_0}{2l}-\frac{3g_0}{2l_n}\Big)\sin\theta\,c,$$
$$d_g(s)=\Big(\frac{3}{ml^2}-\frac{3}{m_nl_n^2}\Big)c.$$

取 $m=l=1$、$m_n=l_n=1.4$，漂移误差的系数约为 $15-10.714=4.286$，输入增益误差的系数约为 $3-1.093=1.907$。因此，同一状态下的残差仍随力矩 u 改变。只以状态为输入的 GP 无法区分这种差异，会将不同动作对应的残差混合拟合；CBF 改变候选动作时，原预测均值及方差也未显式反映残差随动作的变化。这正是采用复合核 GP 的原因。

A.1.2 复合核 GP 的后验

先对单个状态分量推导，暂省分量下标 j。设漂移误差与增益误差的先验独立，$d_f\sim\mathcal{GP}(0,k_f)$、$d_g\sim\mathcal{GP}(0,k_g)$，观测为 $y_t=d_f(s_t)+d_g(s_t)u_t+\nu_t$，其中 $\nu_t\sim\mathcal{N}(0,\sigma_\nu^2)$ 且相互独立。复合核 [13] 给出

$$\mathrm{Cov}(y_t,y_\tau)=k_f(s_t,s_\tau)+u_t\,k_g(s_t,s_\tau)\,u_\tau+\sigma_\nu^2\delta_{t\tau}, \tag{A.3}$$

其中 $\delta_{t\tau}$ 为 Kronecker 符号。对 N 条训练样本，记 $\mathsf{S}=[s_1,\dots,s_N]^\top$、$Y=(y_1,\dots,y_N)^\top$、$U=\mathrm{diag}(u_1,\dots,u_N)$，则 $K=K_f+UK_gU+\sigma_\nu^2I$，其中 $(K_f)_{t\tau}=k_f(s_t,s_\tau)$，$K_g$ 同理。

在查询状态 s_* 处，令 $w_* = (d_f(s_*), d_g(s_*))^\top$，其与 Y 的互协方差为 $A^\top$，其中

$$A = \big[\, k_f(\mathsf{S}, s_*),\ U\, k_g(\mathsf{S}, s_*) \,\big] \in \mathbb{R}^{N\times 2}. \tag{A.4}$$

记两项先验标准差为 σ_f, σ_g。由高斯条件分布 [10]，后验均值和协方差为

$$\begin{aligned} \mathbb{E}[w_* \mid Y] &= A^\top K^{-1} Y, \\ \Sigma_* &= \operatorname{diag}(\sigma_f^2, \sigma_g^2) - A^\top K^{-1} A. \end{aligned} \tag{A.5}$$

恢复分量下标，令 $z = (1, u)^\top$，则候选输入 u 对应的残差预测为

$$\mu_{d,j}(s_*, u) = \mu_{f,j}(s_*) + \mu_{g,j}(s_*) u, \qquad \sigma_{d,j}(s_*, u) = \sqrt{z^\top \Sigma_{*,j} z}.$$

将各分量组合，即得正文中的 $\mu_d(s,u)$ 与 $\sigma_d(s,u)$。实现中不显式计算 K^{-1}，而用 Cholesky 分解 $K = LL^\top$ 和 $V = L^{-1}A$ 计算后验协方差 $\Sigma_* = \operatorname{diag}(\sigma_f^2, \sigma_g^2) - V^\top V$，对应 `dynamics_gp.py` 的 `CompoundGP.predict`。

固定超参数。 两个状态分量分别建立 GP。按 $(\theta, \dot\theta)$ 的顺序，先验标准差取

$$\begin{aligned} (\sigma_{f,1}, \sigma_{f,2})^\top &= 0.3\, \frac{3 g_0}{2 l_n} c \approx (8.04 \times 10^{-3},\, 0.161)^\top, \\ (\sigma_{g,1}, \sigma_{g,2})^\top &= 0.5\, g(s) \approx (1.37 \times 10^{-3},\, 2.73 \times 10^{-2})^\top. \end{aligned}$$

观测噪声标准差为 $\sigma_{\nu,j} = 0.02\sigma_{f,j}$。平方指数核 k_f, k_g 对 $(\theta, \dot\theta)$ 的长度尺度分别为 $(1, 50)$、$(10, 50)$。在 $k_\delta = 1.5$ 下，先验输入增益的逐分量下置信界为 $g_j - k_\delta \sigma_{g,j} = 0.25 g_j > 0$，保留了输入增益的符号。

A.1.3 二阶锥约束与字典序求解

固定当前状态 s，对仿射屏障 $h_i(s) = p_i^\top s + q_i$，记

$$b_i = (1-\eta) h_i(s) - p_i^\top [f(s) + \mu_f(s)] - q_i, \qquad \beta_i = p_i^\top [g(s) + \mu_g(s)].$$

正文的安全约束可改写为

$$\phi_i(u) = b_i - \beta_i u + k_\delta \sum_j |p_{ij}| \left\| \Sigma_j^{1/2} (1, u)^\top \right\|_2 \le \epsilon, \tag{A.6}$$

其中 Σ_j 为当前状态处 $(d_{f,j}, d_{g,j})$ 的后验协方差，$\Sigma_j^{1/2}$ 为其对称半正定平方根。每个 ϕ_i 均为凸函数，故 $\phi(u) = \max_i \phi_i(u)$ 也为凸函数，非空的可行集为闭区间。

令候选输入 $u_c = u^{RL} + \bar u_\phi$，力矩区间为 $\mathcal{U} = [-15, 15]$。目标 $|u - u_c| + K_\epsilon \epsilon$ 在 $K_\epsilon \to \infty$ 时按字典序求解：

$$\epsilon^* = \max\Big\{0, \min_{u\in\mathcal{U}} \phi(u)\Big\}, \qquad u^* = \operatorname*{arg\,min}_{u\in\mathcal{U},\, \phi(u)\le\epsilon^*} |u - u_c|.$$

也就是先最小化松弛量，再将候选输入投影到相应可行区间。程序用黄金分割法求 $\min \phi$，用二分法求区间端点，各迭代 100 次；随后检查力矩限幅、松弛量非负性，以及放宽后的约束余量是否不小于 -10^{-7}，检查失败即报错。$K_\epsilon = 10^{12}$ 只用于记录目标值，不参与上述两步求解。

A.1.4 作者代码问题的定量说明

状态与动作错位。 作者 DDPG-CBF 先更新状态再记录，日志中的状态、动作因此为 $S_i = s_{i+1}$、$U_i = u_i$。用于 GP 的标签为 $S_{i+1} - f(S_i) - g(S_i)U_i$。代入真实转移，得到

$$y_i^{\text{old}} = d(s_{i+1}, u_{i+1}) + g(s_{i+1})(u_{i+1} - u_i). \tag{A.7}$$

除真实残差外，标签还混入了相邻动作之差。策略变化与 OU 探索噪声都会影响这一项，却被 GP 当作模型误差学习。每回合还缺少第一条转移 $s_0 \to s_1$，仅得到 199 条样本。

安全过滤后重新采样。 设策略均值为 μ，作者代码对 $\mu + \bar{u}_\phi$ 求得修正 a，过滤后第 i 个约束的余量为 $M_i \geq 0$。实际执行时又采样噪声 $\xi \sim \mathcal{N}(0, \sigma_\pi^2)$，得到 $u = \mu + \bar{u}_\phi + a + \xi$。在作者采用的状态 GP 模型下，余量随之变为

$$M_i + p_i^\top g(s)\xi.$$

当 $p_i^\top g(s)\xi < -M_i$ 时，采样动作会违反该约束。若 $M_i = 0$ 且 $p_i^\top g(s) \neq 0$，其概率为 $1/2$。此外，旧策略概率使用过滤后的均值，新策略概率却使用原始均值 μ'。以新旧方差相同的情形为例，概率比为

$$r = \frac{\mathcal{N}(u; \mu', \sigma_\pi^2)}{\mathcal{N}(u; \mu + \bar{u}_\phi + a, \sigma_\pi^2)}.$$

即使新旧策略参数相同，$\mu' = \mu$，仍有 $r = \exp\{-[(u-\mu)^2 - \xi^2]/(2\sigma_\pi^2)\}$，通常不等于 1。修改后使用原始策略样本及其分布参数计算概率比。

训练与预测的名义模型不一致。 作者 TRPO-CBF 用 $m = l = 2$ 计算训练标签，此时漂移和输入增益的系数分别为 7.5、0.375，标签为 $y = 7.5 \sin\theta\, c + 2.625 u\, c$。预测时却用真实参数 $m = l = 1$，名义重力项已为 $15 \sin\theta\, c$。因此，即使 GP 准确拟合了标签中的漂移误差，叠加后该项也会变为 $22.5 \sin\theta\, c$；标签中的输入相关部分还会被额外计入。修改后训练与预测统一用名义值 1.4。

A.2 车辆跟随

沿用正文 2.1.2 节的位置、速度记号；相邻车辆的位置差和速度差均按前车减后车定义。

位置积分错误引入的输入增益偏差。 以第 4 辆车为例，记实际加速度为 $a_4 = u - k_d v_4$（作者环境未对该车加噪声）。源码先更新速度，再用新速度积分位置，得到

$$v_4^+ = v_4 + a_4 \Delta t, \qquad p_4^+ = p_4 + v_4^+ \Delta t + \tfrac{1}{2} a_4 \Delta t^2 = p_4 + v_4 \Delta t + \tfrac{3}{2} a_4 \Delta t^2.$$

因此，源码仿真器中 $\partial p_4^+ / \partial u = \frac{3}{2}\Delta t^2$，而名义模型中的对应项为 $\frac{1}{2}\Delta t^2$，相差 3 倍。当 $\Delta t = 0.05\,\text{s}$、$u = 100\,\text{m/s}^2$ 时，仅这一项就使单步位置预测相差 $0.25\,\text{m}$。该残差与输入成正比，无法用仅依赖状态的模型完整表示。

相对速度屏障与车距约束。 记车距裕量 $e = \Delta p - 2$，则 $\dot{e} = \Delta v$，正文构造的屏障为 $h = \dot{e} + \alpha e$。在连续时间下，若始终保持 $h \geq 0$，则

$$\frac{\mathrm{d}}{\mathrm{d}t}\big[\exp(\alpha t) e(t)\big] = \exp(\alpha t) h(t) \geq 0, \qquad e(t) \geq e(0)\exp(-\alpha t).$$

因此，从 $e(0) \geq 0$ 的初态出发，保持 $h \geq 0$ 即可维持 2 m 车距约束。离散实现仍采用正文的条件 $h(s_{t+1}) \geq (1-\eta)h(s_t)$。在修正后的位置积分下，输入对下一步屏障的作用为

$$\frac{\partial h(s_{t+1})}{\partial u_t} = \pm\Big(\Delta t + \frac{\alpha}{2}\Delta t^2\Big) = \pm 0.0525\,\mathrm{s}.$$

其中正、负号分别对应车 4–5、车 3–4。满幅输入可使单步 h 改变约 5.25 m/s；纯车距屏障的相应变化仅为 0.125 m。关键差别在于，引入相对速度后，控制输入通过 Δt 的一阶项进入离散约束，而不再仅通过 Δt^2 的位置项起作用。

附录 B 代码修改说明

本附录区分模型与任务调整、实现错误修正和训练配置调整。B.1、B.2 节分别给出倒立摆与车辆跟随的逐文件对照；表中行号对应本次实验使用的源码版本。

B.1 倒立摆

作者源码位于 `RL-CBF-master/pendulum/`。修改后代码以每次运行保存的 `source/` 快照为准，例如 `pendulum/results/final_600ep/<ALG>/seed1/source/`；文件的 SHA256 见对应运行目录的 `run_config.json`。`learner.py` 与 `replay_buffer.py` 未修改。表 B.1 列出具体修改，关键问题的推导见附录 A.1.4。

表 B.1 倒立摆实现与设置的修改对照

问题	作者源码	修改后
模型与安全约束调整（正文 2.1.1 节）		
残差模型	`dynamics_gp.py`：sklearn GP，输入 s；DDPG-CBF 核为 `1.0*RBF(2)+White(0.1)`，TRPO-CBF 为 `C*RBF(10)`；通过最大似然估计选择超参数，优化重启 10 次	`dynamics_gp.py:24-47` 复合核 `CompoundGP`，超参数固定；`:114-117` 计算 $\sigma_{d,j}(s,u)$
CBF 约束形式	`cbf.py`：cvxopt 二次规划，σ 与 u 无关	`cbf.py:47-95`：二阶锥约束，按字典序求解
安全集	DDPG-CBF `cbf.py:20-24`：$\pm\theta \pm 0.05\dot{\theta}$；TRPO-CBF 中角速度项系数为 0.01	`cbf.py:17-18`：`H=[[1,0],[-1,0]]`
目标与松弛	`P=diag(1,1e24)`（DDPG-CBF）或 `diag(1,1e16)`（TRPO-CBF）；ϵ 无非负约束	先最小化非负松弛量，再最小化修正幅值 $\lvert a\rvert$
速度约束	硬约束；DDPG-CBF 中候选动作被计入两次（`cbf.py:44-45`）	默认关闭，可用 `--enforce-speed-limit` 开启，开启时只计入一次

续下页

表 B.1 倒立摆实现与设置的修改对照（续）

问题	作者源码	修改后
代码错误修正（正文 2.2 节）		
转移错位	DDPG-CBF `ddpg.py:364-371` 先执行 `s=s2` 再记录	`ddpg.py:291,308-310` 分别保存 `Observation`、`Action`、`NextObservation`
Actor 动作范围	DDPG-CBF `ddpg.py:411,417`: `env.action_space.high` 实测为 2	`ddpg.py:371`：同步包装器的动作空间，范围为 ± 15
先过滤后采样	TRPO-CBF `trpo.py:280-292`	`trpo.py:288-295`：先采样，再补偿、过滤
概率比	`trpo.py:289,298`：旧策略均值含 $\bar{u}_\phi + a$	`trpo.py:162,310-311`：使用 `Action_RL` 及原始分布参数
名义模型	TRPO-CBF `dynamics_gp.py:29-30` 用 $m = l = 2$，`:63-64` 用 $m = l = 1$	`dynamics_gp.py:10,66-75`：训练与预测统一用名义值 1.4
时间截断	DDPG `ddpg.py:296-299`、DDPG-CBF `:326-329` 存为终止；TRPO `gae.py:54,72-74` 令 $V(s_T) = 0$	DDPG `env_done` 排除截断；TRPO `gae.py:97-112` 用 $V(s_T)$ 自举
GAE 跨回合	`gae.py:80` 在整批序列上计算	`gae.py:103-109` 逐条轨迹计算
KL 检查	`utils.py:162-177` 只检查代理目标是否下降	`utils.py:174-204` `TRUST_REGION_STEP`：实际 KL 超过上限时回退
GP 更新时机	DDPG-CBF `ddpg.py:280-284,387-388`；TRPO-CBF `trpo.py:246-250,322-323`：每批只拟合前 4 个回合，滞后一轮使用	每个回合后重新拟合，并在下一个回合使用
补偿网络	DDPG-CBF `ddpg.py:390-394` 仅训练 $i \le 4$，使用累计路径；TRPO-CBF 在策略更新前用均值修正训练	每 5 个回合用最近一批训练，标签与 s_t 对齐，首轮输出为零
训练配置调整		
价值网络	`gae.py:103-108` 每次一步约束共轭梯度	`gae.py:171-181`：Adam，10 个 epoch，批量 64，学习率 10^{-3}，回报标准化
次要问题		
鲁棒项	TRPO-CBF `cbf.py:35`：$k_\delta \lvert p^\top \sigma \rvert$	$k_\delta \lvert p \rvert^\top \sigma$。对该屏障，两者相同
角度残差	未对 $\pm\pi$ 做周期处理	`dynamics_gp.py:89` 将角度残差折回 $[-\pi, \pi)$
事后裁剪	DDPG-CBF `cbf.py:59-64` 在求解后改写修正量	将力矩限幅纳入求解区间，约束检查失败时报错

续下页

表 B.1 倒立摆实现与设置的修改对照（续）

问题	作者源码	修改后
存储动作	DDPG `ddpg.py:294,298` 存未裁剪动作	先裁剪到动作范围再存储

训练配置调整。 为使四种算法在相同条件下比较，统一环境与初态（`fair_environment.py`），并采用表 D.1 的训练参数。观测缩放与归一化由 `obs_norm.py` 处理；DDPG 改用高斯探索噪声，TRPO 初始标准差设为 3。倒立摆原实现的 BN 层处于推理模式，滑动统计量未更新，相当于固定归一化后的可学习仿射变换；修改后为统一网络配置而移除。这里的 BN 调整与车辆算例中单样本训练模式下的 BN 错误不同。

DDPG-CBF：转移记录与动作范围。 作者代码先更新状态，再记录用于 GP 和补偿网络的数据：

```
s = s2
obs.append(s); action.append(action_)
```

这使状态与动作错位一步，修改后显式保存 (s_t, u_t, s_{t+1})。此外，作者只修改内层 `env.unwrapped.action_space`，外层 `env.action_space` 在 Gym 0.17.3 中仍为 $[-2, 2]$，Actor 因而仍限幅于 ± 2。保持非零摆角静止需要 $|u| = 5|\sin\theta|$；在考察的 $|\theta| \le 1$ 区间内，Actor 无法独自平衡 $|\theta| > \arcsin(2/5) \approx 0.41$ 的状态。修改后同步内外层动作空间为 ± 15。

TRPO-CBF：采样与策略更新。 作者在过滤后的均值周围重新采样：

```
u_bar_ = cbf.control_barrier(self, np.squeeze(prev_obs_expanded),
                             action_dist_mu_RL, f, g, x, std)
action_dist_mu_ = action_dist_mu_RL + u_bar_
action_ = np.random.normal(loc=action_dist_mu_,
                           scale=np.exp(action_dist_logstd_))
```

修改后先从原始策略采样，再补偿并过滤，执行前不再添加采样噪声；策略更新使用原始样本及其分布参数。时间截断时采用价值自举，GAE 按回合计算，线搜索拒绝实际 KL 超限的更新。沿用原线搜索的中间版本短测中，实际 KL 曾达到 0.98。GP 原先滞后 5–9 回合更新，DDPG-CBF 的补偿网络则在第 25 回合后冻结；修改后分别按回合更新 GP、按迭代更新补偿网络。

B.2 车辆跟随

作者源码位于 `RL-CBF-master/car/<ALG>/`，修改后代码位于仓库 `car/`。TRPO 与 TRPO-CBF 共用 `TRPO-CBF/` 的实现；DDPG 与 DDPG-CBF 共用 `DDPG-CBF/ddpg.py`，并从 `TRPO-CBF/` 导入仿真器等模块。两条基线通过 `--no_cbf` 关闭安全滤波及补偿。表 B.2 的“修改后”栏中，未另注目录的文件均位于 `TRPO-CBF/`；源码 SHA256 保存在各运行的 `run_config.json` 中。

表 B.2 车辆跟随实现与设置的修改对照

问题	作者源码	修改后
任务设置、模型与安全约束调整（正文 2.1.2 节）		
制动规则	四份 `car_simulator.py:51-52,62-63`：车距 <6 时 `action-k_brake*gap`（车 5 针对车 3，阈值 12 m、系数减半），名义模型采用同一规则	`car_simulator.py:25-27`：$-k_b\max(0,6-\Delta p)$，名义模型共用 `driver_controls`
软惩罚阈值	`car_simulator.py:105-109`：$d<2.99$，$\lvert 500/d\rvert$	`car_simulator.py:49-50`：$d\le 3$，下限 0.5 m
燃油项	DDPG `car_simulator.py:94` 用 $\lvert v_4\rvert$，其余用 v_4	四种算法统一使用 v_4
屏障	TRPO-CBF `cbf.py:19-27`：8 行 $\Delta p\pm 0.001v-2$；DDPG-CBF `cbf.py:20-28` 系数 0.002	`cbf.py:19-24`：2 行 $\Delta v+2(\Delta p-2)$
QP 求解	`cbf.py:17,57`：cvxopt，`P=diag(1,1e18)`（DDPG-CBF 1e20），松弛量不返回；`:60-65` 事后截断并打印 “Error in QP”	`cbf.py:35-66`：闭式解，返回松弛量
GP 模型	`dynamics_gp.py:18-21`：sklearn `C*RBF`，`alpha=0.5`，10 次重启，15 维绝对状态输入	`dynamics_gp.py:20-28,68-72`：固定超参数，6 维相对特征；`:104` 方差计入观测噪声
GP 标定	无	`trpo.py:221-249`：训练前 400 步随机输入（独立环境），不计入训练量
代码错误修正（正文 2.2 节）		
位置积分	四份 `car_simulator.py:32-33`：先更新速度，再用新速度积分	`car_simulator.py:110-111`：使用更新前的速度积分位置
回放池视图	DDPG `car_simulator.py:83-89,205`、`ddpg.py:291`；DDPG-CBF `ddpg.py:332`：存入同一数组的视图	`car_simulator.py:95-96` 返回副本；DDPG-CBF `ddpg.py:63-67,152,176` 复制到预分配数组
BN 训练模式	DDPG `ddpg.py:75,78,162,268`；DDPG-CBF `ddpg.py:274`：`tflearn.is_training(True)`，单样本调用	DDPG-CBF `ddpg.py:93-104`：移除 BN
补偿网络	TRPO-CBF `trpo.py:134-138,272-273`：只在前 9 次迭代训练，从一开始使用；DDPG-CBF `ddpg.py:308-313`：补偿输出固定为零，`:391-392` 用全部累计路径训练	`trpo.py:138-142,181-182`、DDPG-CBF `ddpg.py:157-158,209-212`：首轮为 0，每次迭代用最近一批训练并使用

续下页

表 B.2 车辆跟随实现与设置的修改对照（续）

问题	作者源码	修改后
先过滤后采样	TRPO-CBF `trpo.py:269-289`：对均值求 CBF，再重新采样	`trpo.py:176-190`：先采样，再补偿、过滤
GP 更新	TRPO-CBF `trpo.py:247-251,327-328`、DDPG-CBF `ddpg.py:281-285,388-389`：每批只用一个回合（79 点），滞后一批使用	`dynamics_gp.py:79-94`：每个回合后用最近 200 条转移重新拟合
TRPO 观测错位	TRPO `trpo.py:228,248,264`：观测序列为 $(s_0, s_0, s_1, \ldots, s_{78})$	`trpo.py:175,200-206`：显式保存 `NextObservation`
终止标志	TRPO `car_simulator.py:68`：`L=100` 而回合为 80 步，`reset` 不清零计数	`car_simulator.py:67`：每回合清零，长度统一由 `config.py` 给出
GAE 与截断	`gae.py:72-80`：在整批序列上计算，时间截断视为终止	`gae.py:58-73`：逐条轨迹计算，截断时用 $V(s_T)$ 自举
KL 检查	`trpo.py:160-178`、`utils.py:166-181`：只检查代理目标	`utils.py:144-173`：实际 KL 超限即拒绝
名义模型	`car_simulator.py:158-193`：读取仿真器当前车辆对象，而非传入的状态	`car_simulator.py:31-46`：改为仅依赖传入状态的函数；原先误读的分量不进入 CBF 或 GP，未影响本次结果
次要问题		
策略标准差	`trpo.py:52` 按自身行数平铺，只影响记录的熵	按批量大小平铺
领头车	$a_1 = k_p(v_{\mathrm{des}}(t) - v_1)$，与论文式 (27) 字面 $a_1 = v_{\mathrm{des}} - 10\sin 0.2t$ 不同	未修改

训练配置与记录。 完整设置见表 D.2 和附录 E.2。奖励在学习更新时乘以 0.01，报告仍使用未缩放回报；TRPO 的采样动作在计算概率比前截断到 ± 100。DDPG 每 5 回合记录并更新一次补偿网络，初态与环境噪声使用独立随机数流。以上调整与表中的实现错误修正分别记录。

每回合的 `episodes.csv` 记录回报、修正量及补偿量 RMS、松弛量和实际 CBF 条件违反次数，并同步生成 TensorBoard 日志。模型每 25 次迭代保存一次；中文路径通过 ASCII 目录链接兼容原运行环境。

附录 C 补充实验结果

本附录给出逐种子结果及约束诊断。回报指回合累计奖励；“前 100”“末 100”均为对应回合的平均回报。碰撞和越界按回合计数，同一回合发生多次仅计一次。修正量与补偿量先逐回合计算 RMS，再对指定回合区间取平均。

C.1 倒立摆

C.1.1 修改后代码的训练结果

图 C.1、C.2 补充正文的越界、修正量及逐种子回报曲线，表 C.1 给出数值结果。数据由 `figures/make_pendulum_figs.py` 计算，完整数值见 `figures/pendulum_metrics.json`。

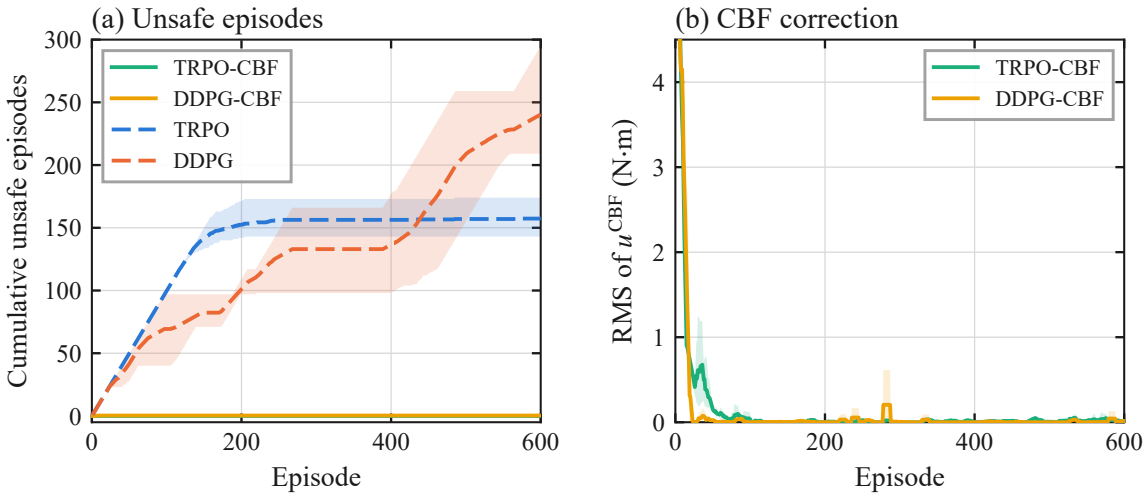


图 C.1 倒立摆的累计越界与 CBF 修正量（修改后代码，种子 1–3）。(a) 累计越界回合数；(b) 每回合修正量 u^{CBF} 的 RMS，作 10 回合滑动平均。粗线为三个种子的均值，阴影为最小值到最大值的范围。

表 C.1 倒立摆各随机种子的训练指标（修改后代码，各 600 回合）

算法	种子	前 100 回报	后 100 回报	越界数 1–100 / 101–300 / 301–600	最大摆角 (rad)	松弛量 >0 的回合
TRPO	1	−1678	−3.39	100 / 73 / 1	3.142	—
TRPO	2	−1284	−3.26	100 / 53 / 2	3.142	—
TRPO	3	−1040	−3.32	100 / 43 / 0	3.142	—
DDPG	1	−630	−65.4	40 / 95 / 82	3.141	—
DDPG	2	−1765	−173.6	97 / 1 / 111	3.141	—
DDPG	3	−3159	−108.4	71 / 95 / 129	3.142	—
TRPO-CBF	1	−144.8	−3.10	0 / 0 / 0	0.99996	1
TRPO-CBF	2	−103.6	−4.27	0 / 0 / 0	0.99996	1, 4
TRPO-CBF	3	−117.5	−3.19	0 / 0 / 0	0.99996	1
DDPG-CBF	1	−28.0	−3.57	0 / 0 / 0	0.99997	1, 7, 8
DDPG-CBF	2	−27.6	−3.33	0 / 0 / 0	0.99997	1, 5, 7, 9
DDPG-CBF	3	−33.5	−5.60	1 / 0 / 0	1.103	1, 7, 8

安全性与训练波动。 两种 CBF 版本首回合回报约为 −150 至 −200。TRPO 基线前 100 回合均越界，第 300 回合后基本不再越界；DDPG 的越界持续至训练结束。TRPO-CBF 种子 2 与 DDPG-CBF 种子 3 在后期偶有较差回报（图 C.2）。正松弛仅出现在前 9 回合，最大值为 0.096，对应 DDPG-CBF 种子 3 的第 7 回合，也是唯一一次越界。

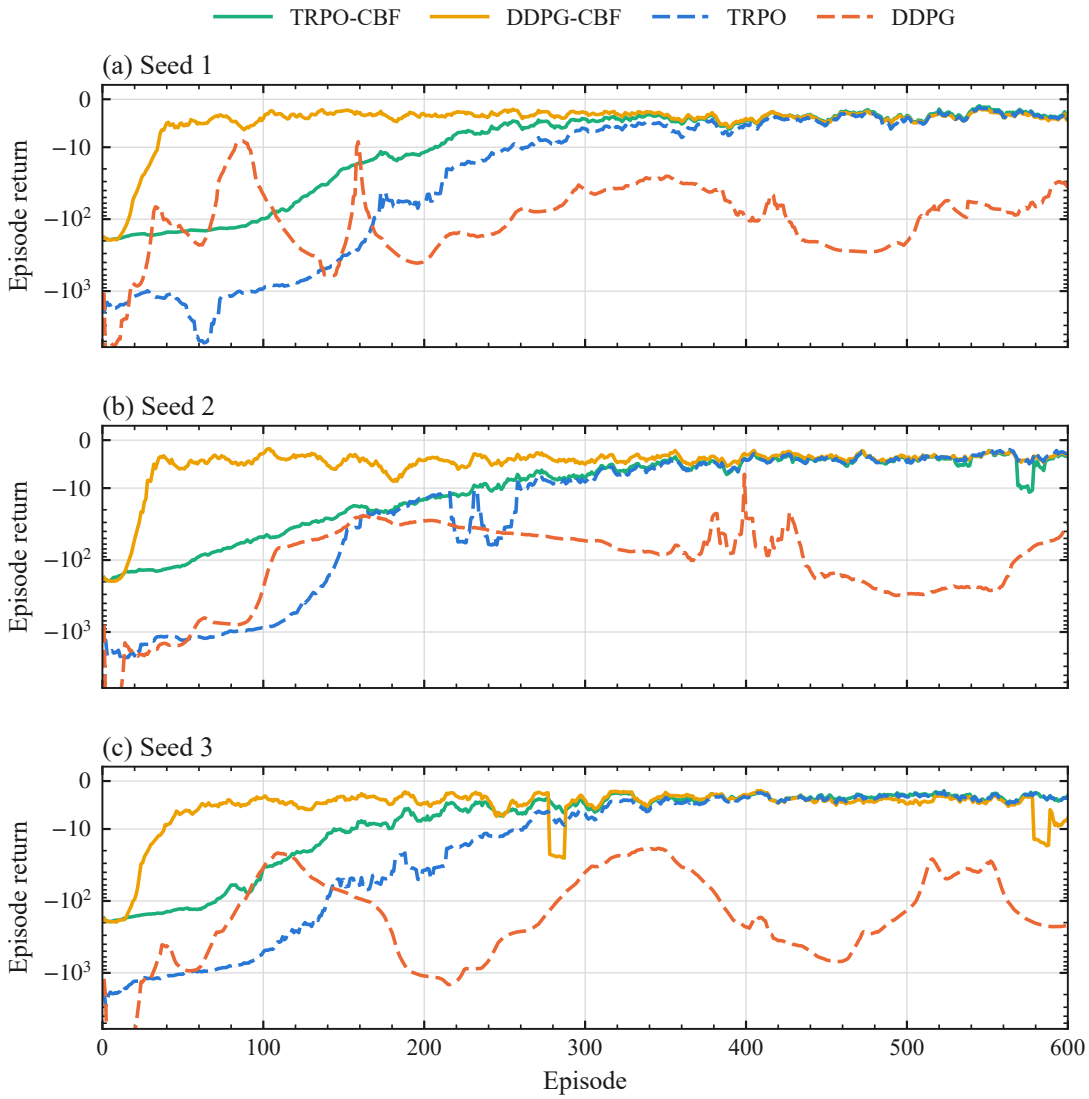


图 C.2 倒立摆各随机种子的训练回报（修改后代码，各 600 回合）。每个子图对应一个种子，四种算法共用初态序列。曲线为 10 回合滑动平均，纵轴采用对称对数刻度（$|R| \le 10$ 的部分为线性）。正文图 1(b) 汇总这三组曲线的均值与范围。

C.1.2 作者源码在默认设置下的结果

图 C.3、表 C.2 给出源码原样重跑的结果。作者文件与默认超参数均保留，仅由外部脚本补设种子并关闭 `env.render()`。默认训练长度为：DDPG 600 回合，DDPG-CBF 150 轮、每轮 5 回合，共 750 回合；TRPO 和 TRPO-CBF 各 9015 回合。后两者的停止条件为步数严格大于 1.8×10^6，因而多运行一批。图中比较前 600 回合，表中另列完整训练结束时的回报。

统计口径与任务差异。 逐回合数据由 `figures/extract_original.py` 从作者输出的 `.mat` 提取。DDPG 类记录执行后状态，TRPO 类记录执行前状态，最大摆角均取每回合 200 个记录状态的最大值。CBF 版本从安全集内出发，记录时点差异不改变其越界计数。作者两条基线使用 ± 2 力矩，初始摆角 $\theta_0 \sim U[-\pi, \pi]$，任务与 CBF 版本不同，其越界数主要反映初态分布和摆起过程。

主要现象。 TRPO-CBF 种子 1、2 在第 64–65 回合达标，种子 3 在前 600 回合未达标，三个阶段的越界数为 6、97、229。种子 3 的最大摆角仅 1.007 rad，与策略停留在边界附近、过滤后重新采样引起小幅越界的现象相吻合。DDPG-CBF 最大摆角约 1.34 rad，末 100 回合回报为 −63 至 −96，修正量 RMS 由初期种子均值 7.7 降至各种子的 1.8–4.4 N · m，训练后仍依赖安全滤波。

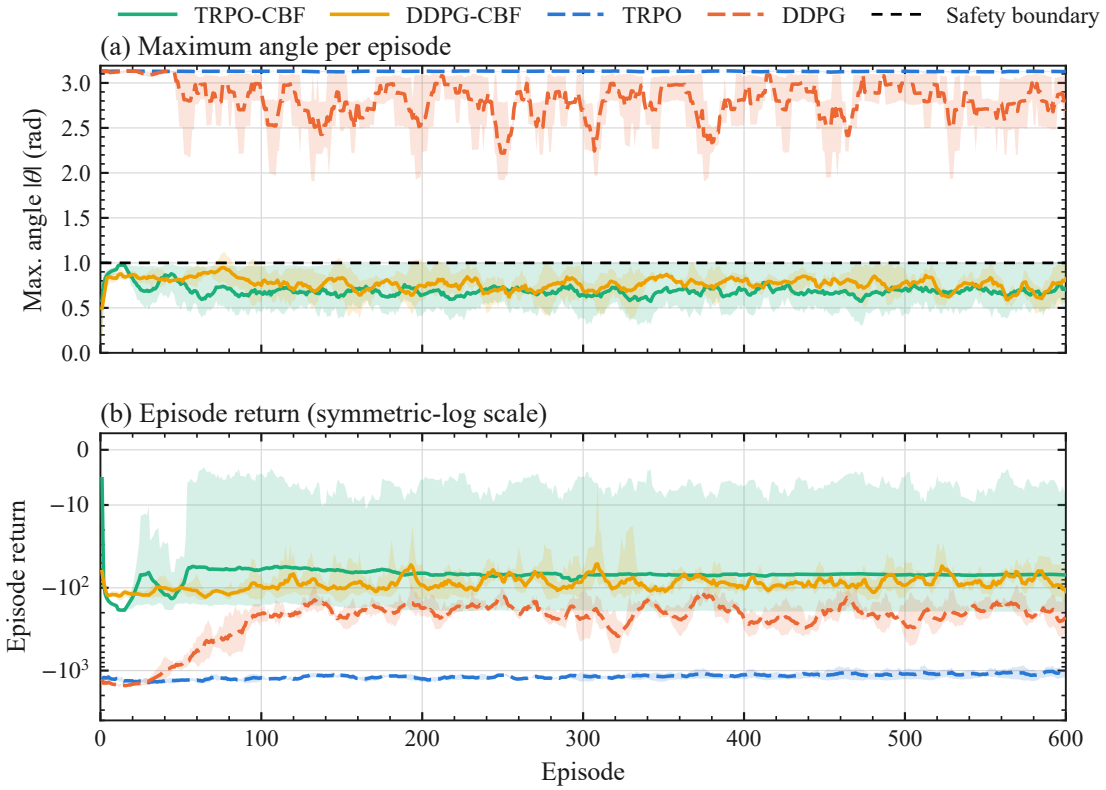


图 C.3 倒立摆作者源码的训练曲线（默认设置，种子 1–3，前 600 回合）。平滑及种子汇总方式同正文图 1。两条基线使用 ±2 力矩，$\theta_0 \in [-\pi, \pi]$，任务设置与 CBF 版本不同，相关指标不宜直接比较。TRPO-CBF 的均值主要受未收敛的种子 3 影响，种子 1、2 的回报接近阴影上沿。

表 C.2 作者源码各随机种子指标（默认设置）

算法	种子	前 100 回报	第 501–600 回报	前 600 个的越界数 1–100 / 101–300 / 301–600	最大摆角 (rad)	完整训练回合数	完整训练末 100 个回报
TRPO†	1	−1280	−972.3	100 / 200 / 300	3.142	9015	−901.4
TRPO†	2	−1248	−1017.3	100 / 200 / 300	3.142	9015	−167.2
TRPO†	3	−1345	−1246.7	100 / 200 / 300	3.142	9015	−469.8
DDPG†	1	−718	−221.5	95 / 173 / 266	3.142	600	−221.5
DDPG†	2	−784	−166.5	94 / 179 / 272	3.142	600	−166.5
DDPG†	3	−902	−212.9	98 / 175 / 273	3.142	600	−212.9
TRPO-CBF	1	−57	−8.2	1 / 0 / 0	1.002	9015	−8.2
TRPO-CBF	2	−44	−7.1	9 / 0 / 0	1.007	9015	−5.4
TRPO-CBF	3	−162	−194.0	6 / 97 / 229	1.007	9015	−38.2

续下页

表 C.2 作者源码各随机种子指标（续）

算法	种子	前 100 回报	第 501–600 回报	前 600 个的越界数 1–100 / 101–300 / 301–600	最大摆角 (rad)	完整训练回合数	完整训练末 100 个回报
DDPG-CBF	1	−102	−95.7	12 / 46 / 69	1.344	750	−93.6
DDPG-CBF	2	−122	−88.4	20 / 22 / 25	1.329	750	−93.2
DDPG-CBF	3	−107	−62.9	13 / 5 / 19	1.288	750	−55.6

† 作者基线为 ±2 力矩、$\theta_0 \in [-\pi, \pi]$ 的摆起任务。完整训练中 TRPO-CBF 种子 3 共越界 616 次。

C.2 车辆跟随

图 C.4–C.6、表 C.3 给出车辆跟随的逐种子结果，数据由 `figures/make_car_figs.py` 计算，完整数值见 `figures/car_metrics.json`。

作者源码：安全性与训练后期表现。 两种 CBF 版本均无碰撞，但存在小幅 2 m 越界：TRPO-CBF 出现在种子 1 第 2068 回合和种子 3 第 29 回合，最小车距分别为 1.968、1.925 m；DDPG-CBF 出现在种子 2 的第 149–358 回合之间，共 10 回合，最小车距为 1.93–1.98 m。TRPO-CBF 种子 1 末 1000 回合中，仍有一半回合的修正量 RMS 大于 $1\,\mathrm{m/s^2}$，种子 2、3 则均不超过该值。DDPG-CBF 全部 1000 回合的修正量平均 RMS 为 40–51 $\mathrm{m/s^2}$，每回合均有 CBF 介入；回报虽从约 -4.8×10^4 提高至 -2.9×10^4，第 4 辆车仍贴近约 2.26 m 行驶，修正量反而增大。

TRPO 三个种子在前 600 回合分别碰撞 310、452、599 次，最后一次碰撞发生在第 13556、10579、21316 回合，默认训练结束时均不再碰撞。DDPG 的车距中位数为 0.63、−3.93、−13.53 m，回报最低约为 -7.2×10^7；作者环境在两车穿过后继续仿真，$|500/d|$ 在 $d \to 0$ 附近会产生很大的惩罚。

修改后：松弛量与模型置信区间。 CBF 采用闭式解，未发生求解器数值失败，最大松弛量为 0.25。TRPO-CBF 仅种子 1 的第 6 回合、种子 2 的第 4 回合出现正松弛；DDPG-CBF 三个种子分别有 7、12、3 回合出现正松弛。其中种子 1 为第 1、10、546、551、556、559、606 回合，种子 2 分布在第 4–1295 回合，种子 3 为第 11、26、67 回合。

对整回合松弛量均为零的记录，统计实际转移不满足 $h(s_{t+1}) \geq (1-\eta)h(s_t)$ 的回合数。模型预测可行而实际条件未满足，说明相应置信区间未覆盖该步残差。TRPO-CBF 三个种子分别有 1、5、2 个此类回合，均发生于前 64 回合；DDPG-CBF 分别有 87、102、209 个，分布于整个训练过程，这些回合均未越界。DDPG 的碰撞仅发生在前 8000 步；TRPO 种子 3 在 13.3 万步后不再碰撞。TRPO-CBF 种子 3 的末 100 回合回报与收敛后的 TRPO 相当（−715 对 −738）。DDPG-CBF 末 100 回合的补偿输出 RMS 分别为 94.0、98.0、92.1 $\mathrm{m/s^2}$，种子 3 的 CBF 修正量仍为 10.3 $\mathrm{m/s^2}$。

作者日志的统计方式。 `figures/extract_car_original.py` 将作者 `.mat` 按 80 步切分回合，TRPO 类每批 1200 步。TRPO、TRPO-CBF、DDPG-CBF 记录执行前状态；DDPG 因状态数组被原地改写而记录执行后状态，均已与固定初态核对。作者代码不返回 QP 松弛量，表中记为 “未记录”。重跑时未出现 `Error in QP` 提示，但这不能代替松弛量统计。

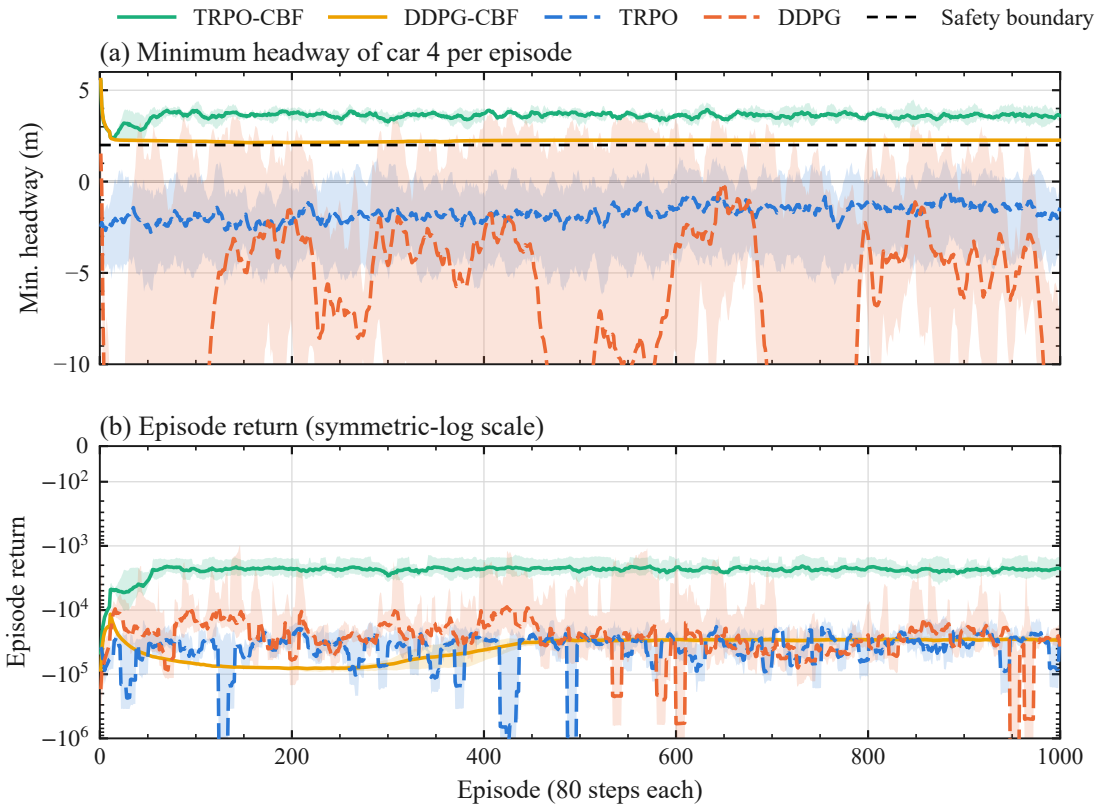


图 C.4 车辆跟随作者源码的训练曲线（默认设置，种子 1–3，前 1000 回合）。每回合 80 步，横轴为回合；两种 DDPG 的全部训练均在图内，TRPO 类完整结果见表 C.3。(a) 每回合最小车距，纵轴显示 $[-10, 6]$ m，DDPG 的实际最低值约为 -153 m；(b) 回报，采用对称对数刻度。平滑及种子汇总方式同正文图 3。

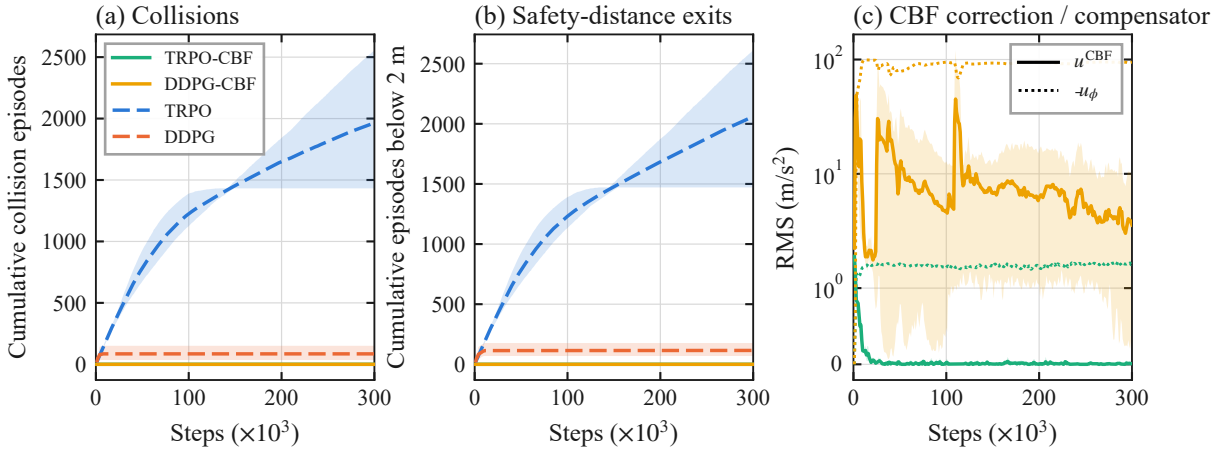


图 C.5 车辆跟随的累计安全事件与安全修正（修改后代码，种子 1–3，横轴为环境步数）。(a) 累计碰撞回合数；(b) 累计 2 m 越界回合数；(c) CBF 修正量 u^{CBF} 的 RMS（实线）及补偿输出 $\bar{u}_\phi$ 的 RMS（点线），采用对称对数刻度。曲线经 10 回合滑动平均后取种子均值，阴影为最小值到最大值的范围。

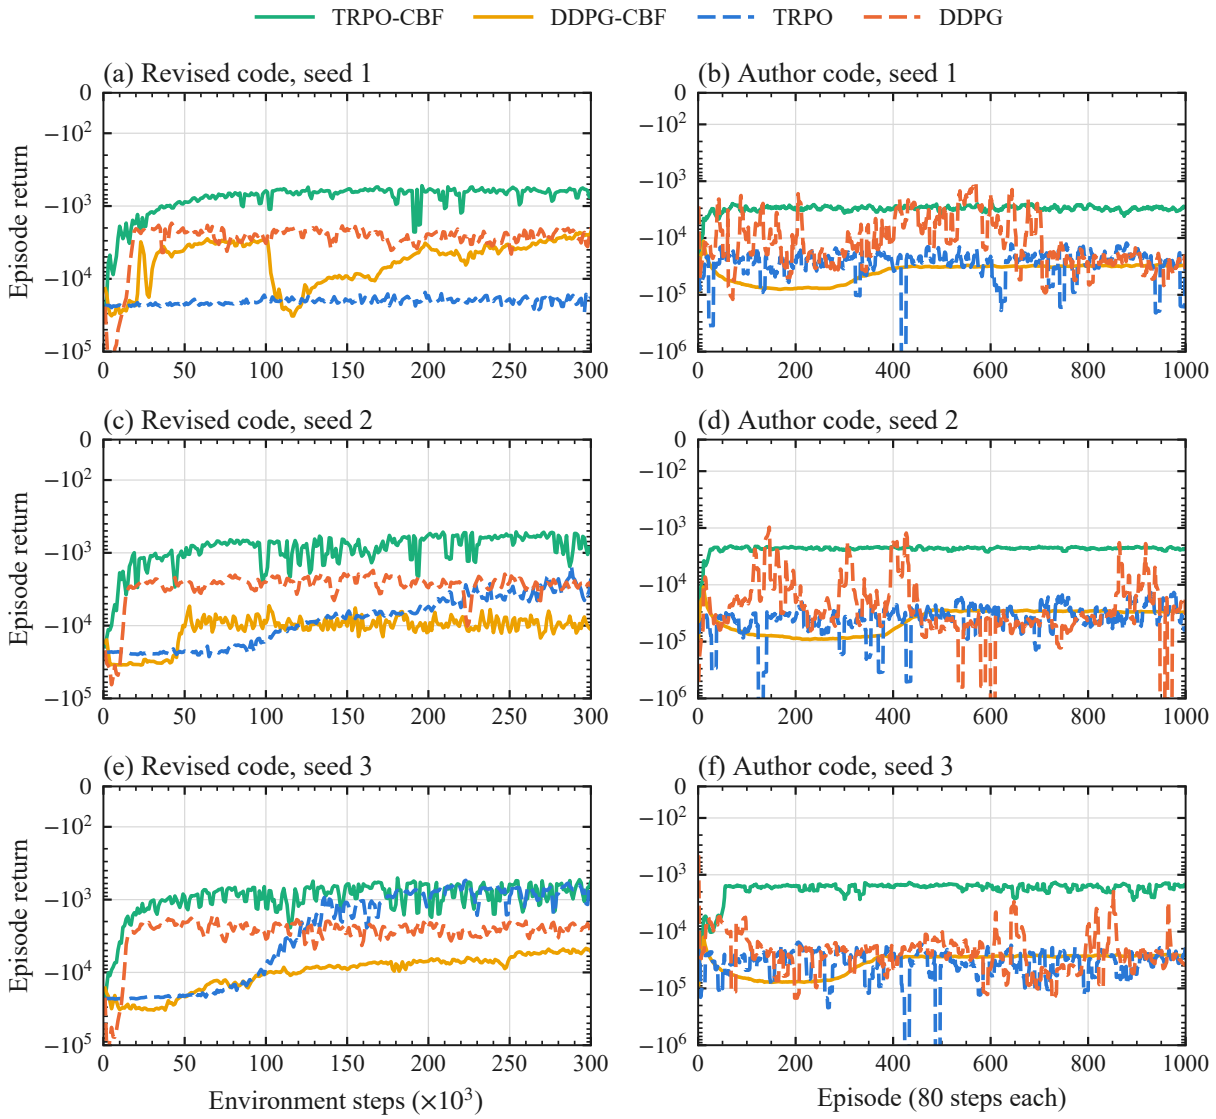


图 C.6 车辆跟随各随机种子的训练回报。左列为修改后代码，横轴为环境步数；右列为作者源码的前 1000 回合，横轴为回合。曲线均作 10 回合滑动平均，纵轴采用对称对数刻度。修改后，同一子图内四种算法共用初态与噪声序列；作者 TRPO 类的种子由外部脚本设置。

表 C.3 车辆跟随各随机种子的训练指标

算法	种子	回合数	前 100 回报	末 100 回报	碰撞回合数（训练回合四等分）	越界数	最小间距	修正量 RMS 前 10 → 末 100	松弛量 > 0 的回合数
作者源码，默认设置（每个回合 80 步）									
TRPO	1	22515	−59731	−2617	1234 / 10 / 3 / 0	3634	−6.82	—	—
TRPO	2	22515	−73579	−1734	823 / 2 / 0 / 0	3575	−6.74	—	—
TRPO	3	22515	−47948	−2118	5583 / 1484 / 14 / 12	9824	−10.82	—	—
DDPG	1	1000	−23740	−36413	104 / 79 / 52 / 227	623	−66.77	—	—
DDPG	2	1000	−33339	−887181	142 / 128 / 248 / 170	804	−70.97	—	—
DDPG	3	1000	−20708	−28026	247 / 249 / 201 / 181	927	−152.63	—	—
TRPO-CBF	1	15015	−3849	−3496	0 / 0 / 0 / 0	1	1.97	13.40 → 4.50	未记录
TRPO-CBF	2	15015	−2968	−1981	0 / 0 / 0 / 0	0	2.14	12.04 → 0.00	未记录

续下页

表 C.3 车辆跟随各随机种子的训练指标（续）

算法	种子	回合数	前 100 回报	末 100 回报	碰撞回合数（训练回合四等分）	越界数	最小间距	修正量 RMS 前 10 → 末 100	松弛量 > 0 的回合数
TRPO-CBF	3	15015	−4573	−1438	0 / 0 / 0 / 0	1	1.93	15.34 → 0.00	未记录
DDPG-CBF	1	1000	−47777	−30741	0 / 0 / 0 / 0	0	2.08	22.03 → 31.16	未记录
DDPG-CBF	2	1000	−49705	−29802	0 / 0 / 0 / 0	10	1.93	20.64 → 30.45	未记录
DDPG-CBF	3	1000	−47466	−26267	0 / 0 / 0 / 0	0	2.09	22.31 → 26.98	未记录
修改后代码（每个回合至多 200 步，3×10^5 步）									
TRPO	1	2652	−23645	−19845	660 / 640 / 627 / 637	2620	−0.25	—	—
TRPO	2	2219	−23014	−2928	555 / 544 / 535 / 274	2099	−0.56	—	—
TRPO	3	2395	−23068	−738	599 / 599 / 234 / 0	1471	−0.38	—	—
DDPG	1	1550	−88097	−2485	69 / 0 / 0 / 0	100	−1.51	—	—
DDPG	2	1625	−38224	−2825	151 / 0 / 0 / 0	177	−1.53	—	—
DDPG	3	1525	−46149	−2447	35 / 0 / 0 / 0	69	−1.58	—	—
TRPO-CBF	1	1500	−4957	−631	0 / 0 / 0 / 0	0	2.46	1.38 → 0.00	1
TRPO-CBF	2	1500	−5180	−872	0 / 0 / 0 / 0	0	2.48	1.46 → 0.01	1
TRPO-CBF	3	1500	−5573	−715	0 / 0 / 0 / 0	0	2.41	1.29 → 0.01	0
DDPG-CBF	1	1500	−24901	−2556	0 / 0 / 0 / 0	0	2.37	33.32 → 0.37	7
DDPG-CBF	2	1500	−32259	−9926	0 / 0 / 0 / 0	0	2.33	40.64 → 1.11	12
DDPG-CBF	3	1500	−27669	−5085	0 / 0 / 0 / 0	0	2.38	17.91 → 10.25	3

最小间距为全程最小值，单位 m；修正量 RMS 单位 $\mathrm{m/s^2}$。作者环境在两车穿过后继续仿真，间距可为负。两组回报仅作组内比较。

训练所得策略的闭环仿真。 正文图 4 使用各次训练最后保存的策略，部署在修改后的真实动力学上。模型迭代次数见表 C.4：CBF 版本与 DDPG 通常为第 300 次，DDPG 种子 2 为第 325 次，TRPO 为第 250–275 次。执行采用确定性动作，CBF 版本保留补偿网络与安全滤波器；GP 重新标定，并用 5 个预热回合拟合后冻结。

所有算法与种子共用 `allCars(init_seed=2026,noise_seed=3026)` 生成的初态和噪声，仿真 200 步（10 s）。车 1–3 不受第 4 辆车控制影响，因此各算法面对相同的前车，其速度由约 30 降至 20 m/s。模型来自 `car/results/car_final/<ALG>/seed<k>/checkpoint/`；表 C.4 汇总三个种子的指标，图 C.7 补充种子 2、3 的轨迹及 CBF 修正。回报按原奖励逐步累加，含 3 m 软约束惩罚；此处未加入探索噪声，回报与训练时不宜直接比较。

表 C.4 车辆跟随训练结束时策略的闭环仿真指标（修改后代码，10 s）

算法	种子	模型迭代	碰撞	最小车距（m）及出现时刻	输入 RMS（$\mathrm{m/s^2}$）	回报	u^{CBF} RMS（$\mathrm{m/s^2}$）	CBF 介入步数比例
TRPO-CBF	1	300	否	3.31 (8.6 s)	1.3	−580	0.00	0%
TRPO-CBF	2	300	否	3.60 (8.2 s)	1.2	−562	0.00	0%
TRPO-CBF	3	300	否	3.63 (8.1 s)	1.2	−552	0.00	0%
DDPG-CBF	1	300	否	3.21 (8.0 s)	1.6	−1024	0.00	0%
DDPG-CBF	2	300	否	2.46 (7.6 s)	1.6	−22996	1.40	62%
DDPG-CBF	3	300	否	2.83 (8.6 s)	4.3	−5943	11.69	55%
TRPO	1	275	是（7.0 s）	−0.03 (7.0 s)	0.7	−15310	—	—
TRPO	2	250	否	0.76 (10.0 s)	2.7	−2537	—	—

续下页

表 C.4 车辆跟随训练结束时策略的闭环仿真指标（续）

算法	种子	模型迭代	碰撞	最小车距（m）及出现时刻	输入 RMS (m/s^2)	回报	u^{CBF} RMS (m/s^2)	CBF 介入步数比例
TRPO	3	275	否	3.31 (8.2 s)	1.3	−627	—	—
DDPG	1	300	否	3.10 (5.2 s)	1.3	−627	—	—
DDPG	2	325	否	3.29 (4.0 s)	1.8	−792	—	—
DDPG	3	300	否	3.08 (5.2 s)	1.3	−662	—	—

“模型迭代”为最后保存的模型所对应的训练迭代次数；TRPO 因碰撞提前结束回合，3×10^5 步内未到第 300 次迭代。

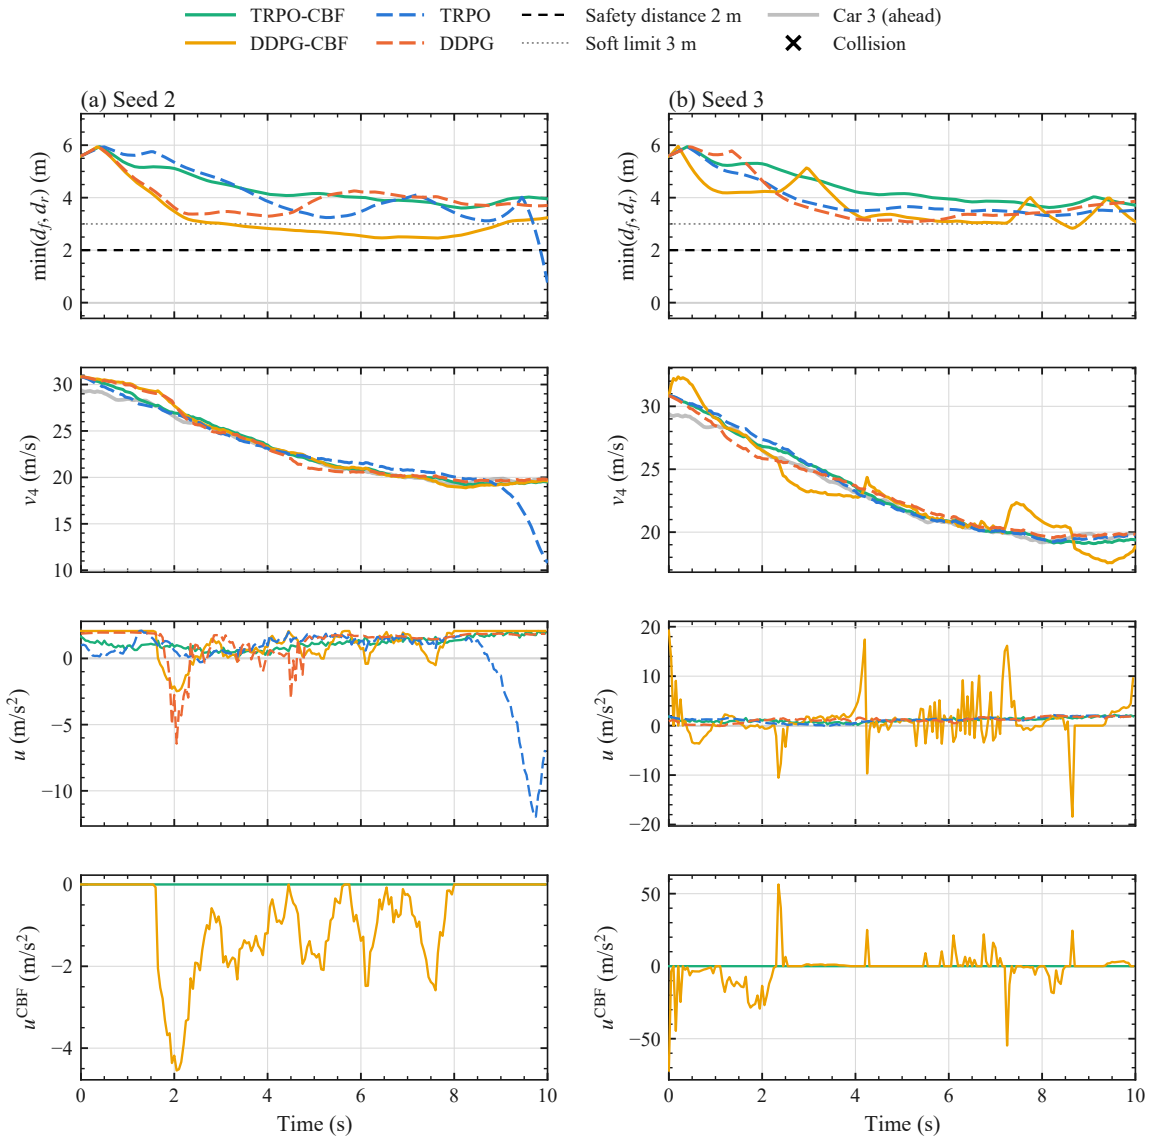


图 C.7 车辆跟随训练后策略的闭环响应（种子 2、3，设置同正文图 4）。自上而下为第 4 辆车与前、后车的最小间距、车速（灰线为车 3）、执行输入，以及两种 CBF 版本的修正量 u^{CBF}。DDPG-CBF 种子 3 的修正量在 -72 至 $+56\,m/s^2$ 之间变化，至仿真末期仍有明显介入。

DDPG-CBF 种子 2 的回报远低于其他运行，其车距有 5.9 s 处于 2–3 m 之间，持续产生软约束惩罚，同时仍满足 2 m 安全间距。完整数值见 `figures/car_final_sim.json`。

闭环仿真数据进一步显示，DDPG-CBF 种子 1 的 Actor、补偿网络与执行输入均值分别为 -91.9、93.1、$1.2\,\mathrm{m/s^2}$；种子 2 分别为 100.0、-97.9、$1.2\,\mathrm{m/s^2}$，其中 Actor 全程处于输出上限。种子 3 的 Actor 在 66% 的步数上满足 $|u^{RL}| \geq 95$，Actor、补偿网络与执行输入均值分别为 -22.7、25.7、$1.1\,\mathrm{m/s^2}$。输出抵消的方向随种子变化。这些输出日志支持正文关于相互抵消偏置与饱和的机理分析；梯度减弱仍属于推断，最终版本未做消融或梯度测量。

附录 D 复现运行说明

两个算例均在 Windows 11、CPU 环境运行，使用 Python 3.7.9、TensorFlow 1.15.0、tflearn 0.3.2、Gym 0.17.3、NumPy 1.18.5、SciPy 1.4.1、scikit-learn 0.22.2.post1 和 cvxopt 1.2.7，绘图使用 matplotlib 3.2.2。代码、数据与 TensorBoard 日志位于仓库 `RL-CBF-Reproduction/`，目录结构见 `README.md`。以下按算例列出参数、训练命令和评估流程；命令中的目录参数需替换为实际路径。

D.1 倒立摆

表 D.1 倒立摆完整参数（修改后设置）

项目	DDPG / DDPG-CBF	TRPO / TRPO-CBF
环境	Pendulum-v0，$m = l = 1$，$g_0 = 10$，$\Delta t = 0.05$，力矩 ± 15，角速度 ± 60，每个回合 200 步；初态 $\theta_0, \dot{\theta}_0 \sim U[-1, 1]$，由 `RandomState(1234+seed)` 生成	
种子与训练量	种子 1、2、3；启动上限为 2000 回合，获得前 600 回合后停止并截取，报告这 600 回合的结果	
折扣与更新参数	$\gamma = 0.99$；目标网络软更新系数 $\tau = 10^{-3}$	$\gamma = 0.99$，$\lambda = 0.95$
网络	Actor、Critic 隐藏层均为 400–300 ReLU，无 BN；Actor 输出为 15 tanh	策略网络 64-64 ReLU；价值网络 100-50-25 tanh
优化	Actor 学习率 10^{-4}，Critic 学习率 5×10^{-4}，批量 256，回放池 10^5，每步更新	KL ≤ 0.005，回溯 20 次；价值网络用 Adam（10^{-3}，10 个 epoch，批量 64）
探索	独立高斯噪声 $\sigma = 1$	初始 $\log \sigma = \ln 3$
观测处理	运行均值与方差归一化，截断到 ± 10，每 5 个回合更新	固定缩放 $[\cos\theta, \sin\theta, \dot{\theta}/8]$
迭代	补偿网络与归一化每 5 个回合更新一次	每批 1000 步（5 个回合）
CBF	$h = 1 \pm \theta$，$\eta = 0.5$，$k_\delta = 1.5$，$\epsilon \geq 0$，按字典序求解；无速度约束；名义模型 $m = l = 1.4$；复合核 GP 超参数见附录 A.1.2，每个回合后用该回合的 200 条转移重新拟合	
补偿网络	50-40 ReLU，最多 100 个梯度步，步长 10，线搜索回溯 30 次；输入与策略网络使用相同的观测处理	

训练与运行记录。 以下路径均相对于仓库的 pendulum/。四种算法的训练入口分别位于 DDPG/、DDPG-CBF/、TRPO/、TRPO-CBF/。单次运行命令为

```
python scripts/run_one.py --alg TRPO-CBF --seed 1 --episodes 600 --run-dir <RUN_DIR>
```

脚本显式传入表 D.1 的超参数,将源码复制到运行目录的 source/,并在 run_config.json 中记录命令行参数和源码 SHA256。运行目录必须为新目录；每回合输出一行 LIVE 指标。scripts/launch_all.py 用于并行启动多个算法和种子,scripts/export_first_n.py 截取前 N 回合，生成 results/final_600ep/。

训练前后策略的闭环评估。 正文图 2 使用 scripts/run_ckpt.py 重跑种子 1，其训练配置与 run_one.py 相同，仅通过外部包装增加检查点保存。训练前后全部 TensorFlow 变量分别保存在 ckpt/first、ckpt/last，另存最终 GP 状态及 TRPO 参数。评估命令为

```
python scripts/eval_ckpt.py --run-dir <RUN_DIR>
```

脚本重建计算图并恢复策略参数，从 RandomState(2026) 生成的同一组 10 个初态出发,以确定性动作各仿真 200 步 (10 s)。初始策略配合零补偿与 GP 先验，训练后策略配合训练所得补偿网络与最终 GP 后验；两阶段均保留安全滤波，评估期间不更新 GP。轨迹写入 eval_first_last.npz，结果目录为 results/checkpoint_rerun_seed1/。

作者源码原样重跑。

```
python scripts/launch_orig.py --root <RUN_ROOT> --orig-root <ORIG_ROOT>/pendulum
```

脚本原样复制作者文件,仅在外部补设种子并关闭渲染。作者输出的 .mat 共约 515 MB,未纳入仓库；results/author_code_default/ 保存从中提取的逐回合 episodes.csv、run_config.json 和控制台日志。提取脚本为 report/figures/extract_original.py。

图表与 TensorBoard。 在 report/ 下运行

```
python figures/make_pendulum_figs.py
```

脚本读取逐回合 CSV 与 eval_first_last.npz，生成倒立摆图形及 pendulum_metrics.json。在 pendulum/ 下运行 python scripts/csv_to_tensorboard.py，将 final_600ep 和 author_code_default 的记录转换为仓库根目录 tensorboard/ 中的日志，运行名为“结果组/种子/算法”。随后在仓库根目录运行 tensorboard --logdir tensorboard，查看回报、最大摆角、越界数及 CBF 修正量。

D.2 车辆跟随

车辆训练设置三个 BLAS 线程变量 OMP_NUM_THREADS、MKL_NUM_THREADS、OPENBLAS_NUM_THREADS 为 1，并设置 CUDA_VISIBLE_DEVICES=-1、MPLBACKEND=Agg。修改后参数见表 D.2，与作者默认设置的对照见附录 E.2。

表 D.2 车辆跟随完整参数（修改后代码；四种算法相同的项合并列出）

项目	DDPG / DDPG-CBF	TRPO / TRPO-CBF
动力学与噪声	五辆车，$\Delta t = 0.05\,\mathrm{s}$，$k_d = 0.1$，$k_p = 4$，$k_b = 20$，$v_{\mathrm{des}} = 30\,\mathrm{m/s}$；领头车目标车速为 $30 - 10\sin(0.2t)$；五辆车均加入标准差 $1\,\mathrm{m/s^2}$ 的独立高斯加速度噪声	
制动与积分	制动项为 $-k_b \max(0, 6 - \Delta p)$；车 5 对车 3 为 $-\frac{1}{2}k_b \max(0, 12 - \Delta p_{35})$，其中 $\Delta p_{35} = p_3 - p_5$；输入限幅 $\pm 100\,\mathrm{m/s^2}$；使用更新前的速度积分位置	
初态与回合	每回合至多 200 步；间距 $6 \pm 0.5\,\mathrm{m}$、速度 $30 \pm 1\,\mathrm{m/s}$ 均匀随机，车 5 初始位置为 10 m。初态与噪声分别由 `RandomState(1233+seed)`、`RandomState(4320+seed)` 生成	
奖励与终止	$-v_4 \max(a_4, 0) - \sum_{d \in \{d_f, d_r\}} 500/\max(d, 0.5) \cdot \mathbf{1}_{\{d \le 3\}}$；$\min(d_f, d_r) \le 0$ 时终止并给 $-(500 + 100 \times$ 剩余步数$)$；时间截断用价值自举；学习时奖励乘 0.01	
观测	10 维：4 个相邻间距 /10、5 个速度 $(v - 30)/5$、第 4 辆车加速度 /10；GP 与 CBF 使用原始物理状态	
种子与训练量	种子 1、2、3；每种算法 3×10^5 步；CBF 版本训练前另用 400 步（独立环境、输入 $\mathcal{N}(0,1)$）标定 GP	
折扣与迭代	$\gamma = 0.99$，目标网络软更新系数 $\tau = 10^{-3}$；每 5 个回合为一轮	$\gamma = 0.995$，$\lambda = 0.95$；每批 1000 步
网络	Actor、Critic 隐藏层均为 128–128 ReLU，无 BN；Actor 输出 100 tanh；动作除以 100 后与状态特征拼接，输入 Critic	策略网络 64-64 ReLU，初始 $\log\sigma = 0$；价值网络 100-50-25 tanh
优化	Actor 学习率 10^{-4}，Critic 学习率 10^{-3}，批量 64，回放池 10^5，前 1000 步后每步更新一次；回放池存 Actor 原始动作	KL ≤ 0.005（检查实际 KL），回溯 20 次；价值网络 Adam（10^{-3}，10 个 epoch，批量 64，回报标准化）
探索	OU 噪声 $\sigma = 1$，回复速率 0.15，每个回合重置	高斯策略采样，截断到 ± 100
CBF	前、后两对车辆均采用 $h = \Delta v + \alpha(\Delta p - 2)$，$\alpha = 2\,\mathrm{s^{-1}}$，$\eta = 0.2$，$k_\delta = 2$，闭式解，松弛量按 $K_\epsilon \to \infty$ 处理；名义模型 $k_d = 0$、$k_p = 3.5$、$k_b = 18$	
GP	对车 3、4、5 的位置与速度残差各建一个 GP，输入为 6 维相对特征，平方指数核长度尺度 $(3, 3, 3, 5, 5, 5)$；先验标准差位置 0.0075 m、速度 0.3 m/s，观测噪声由噪声标准差推出；每个回合后用最近 200 条转移重新拟合	
补偿网络	50-40 ReLU，输出乘 10 并截断到 ± 100；每轮（迭代）用最近一批数据拟合 $\bar{u}_\phi + u^{CBF}$，最多 100 步、步长 10、回溯 30 次；首轮补偿输出为零	

训练与运行记录。 以下路径均相对于仓库的 `car/`。训练入口位于四个算法目录，环境常数集中在 `TRPO-CBF/config.py`，TRPO 超参数采用 `TRPO-CBF/sim.py` 的默认值。修改后运行命令为

```
python scripts/run_final.py --root <NEW_DIR> --seeds 1 2 3
```

脚本仅向每个算法传入 `--random_seed` 和 `--logroot`，拒绝复用已有目录，并错开前几个进程的启动时间。结果写入 `results/car_final/<ALG>/seed<k>/`，其中 `episodes.csv` 保存逐回合指标，`run_config.json` 记录命令和全部源码 SHA256。

作者源码原样重跑。

```
python scripts/launch_orig.py --root <RUN_ROOT> --orig-root <ORIG_ROOT>/car
```

scripts/run_orig.py 原样复制作者文件并核对 SHA256；TRPO 类运行 sim.py，DDPG 类运行 ddpg.py。外部包装仅补设种子、设置 MPLBACKEND=Agg，并允许 savemat 写长字段名。原始 .mat 未纳入仓库，提取后的逐回合记录、运行配置及控制台日志见 results/car_author_default/。

训练图表与 TensorBoard。 在 report/ 下运行

```
python figures/extract_car_original.py --runs <RUN_ROOT>
```

```
python figures/make_car_figs.py
```

前者从作者 .mat 提取逐回合记录，仓库已附提取结果；后者生成车辆训练图形及 car_metrics.json。在 car/ 下运行 python scripts/csv_to_tensorboard.py，生成 car_final/ 和 car_author_default/ 两组 TensorBoard 日志。

闭环仿真与动画。

```
python scripts/simulate_final.py
```

脚本从 results/car_final/<ALG>/seed<k>/checkpoint/ 恢复最后保存的模型，按正文 3.2 节的协议仿真 10 s。TensorFlow 检查点每个约 0.5–1 MB；逐步数据写入 results/car_eval/sim_seed<k>.npz，指标写入 sim_summary.json。随后运行

```
python scripts/animate_final.py
```

即可生成四种算法并排的 animation_seed<k>.gif 及末帧 _final.png：上部为车道动画，车辆以 1.8 m 标记表示；下部为最小车距、车速和输入曲线。正文图 4 与图 C.7 由 report/ 下的 python figures/make_car_sim_figs.py 生成。

异常重启与重复运行。 作者源码的 12 个运行中，TRPO 种子 1、DDPG 种子 1、DDPG-CBF 种子 2、3 在启动约 5 s 时同时因 Windows 原生异常退出，错误码为 0xc0000409、0xc0000005，无 Python 报错；当时约 16 个 TensorFlow 进程同时初始化。这四次运行按原配置重新启动，间隔 20 s，失败记录另存于 _crashed/。修改后代码的 3000 步重复短测中，TRPO、TRPO-CBF、DDPG-CBF 两次结果一致，DDPG 存在差异；完整训练尚未验证逐位一致性。

附录 E 作者源码与修改后设置对照

本附录对照作者源码默认值与修改后设置，并说明调整目的。训练参数见附录 D，模型与安全约束见正文 2.1 节，具体实现修改见附录 B。

E.1 倒立摆

倒立摆采用 Gym Pendulum-v0[3]，真实参数为 $m = l = 1$，$g_0 = 10\,\mathrm{m/s^2}$，$\Delta t = 0.05\,\mathrm{s}$；名义质量与杆长均为 1.4，分别引入 40% 的误差。目标是在 $|\theta| \le 1\,\mathrm{rad}$ 内稳定于竖直位置，每回合 200 步，奖励为 $-(\theta^2 + 0.1\dot{\theta}^2 + 0.001u^2)$。复现对应论文图 3 的安全性、学习速度与修正量消退，以及图 4 的训练前后策略表现。

表 E.1 给出两组设置。修改后，四种算法使用种子 1、2、3，同一种子共用初态序列；各运行取前 600 回合。作者基线与 CBF 版本的输入限幅和初态不同，相关指标不宜直接比较。训练启动与截取方法见附录 D.1，源码来自作者仓库 `rcheng805/RL-CBF`。

表 E.1 倒立摆主要设置：作者源码默认值与修改后设置

项目	作者源码默认	修改后设置
环境	CBF 版本：力矩 ±15、角速度 ±60；基线：Gym 默认的 ±2、±8	四种算法均为 ±15、±60
初始状态	基线 $\theta_0 \sim U[-\pi,\pi]$；CBF 版本 $\lvert\theta_0\rvert \le 0.8$ 或 ≤ 1；$\dot\theta_0 \sim U[-1,1]$	四种算法均为 $\theta_0, \dot\theta_0 \sim U[-1,1]$
训练量与种子	DDPG 600、DDPG-CBF 750、TRPO 两种各约 9000 个回合；种子 1754、1234、未固定	每种算法 600 个回合，种子 1、2、3
迭代单位	TRPO 每批 15 个回合；DDPG-CBF 每 5 个回合为一轮	统一为 5 个回合；GP 每个回合更新
DDPG	学习率 $10^{-4}/10^{-3}$；回放池 10^6；批量 64；OU 噪声 $\sigma = 0.3$；BN	学习率 $10^{-4}/5\times10^{-4}$；回放池 10^5；批量 256；高斯噪声 $\sigma = 1$；无 BN；运行时观测归一化
TRPO	$\gamma = 0.995$，$\lambda = 0.98$；初始标准差约 1 或 0.37；价值网络单步约束共轭梯度	$\gamma = 0.99$，$\lambda = 0.95$；初始标准差 3；观测 $[\cos\theta, \sin\theta, \dot\theta/8]$；价值网络 Adam
CBF 与 GP	斜向屏障；目标 $\frac{1}{2}a^2 + \frac{1}{2}K_\epsilon\epsilon^2$；额外速度约束；GP 拟合 $d(s)$	屏障 $\lvert\theta\rvert \le 1$；目标 $\lvert a\rvert + K_\epsilon\epsilon$；复合核 GP；$\eta = 0.5$，$k_\delta = 1.5$

表 E.1 中的训练配置调整不属于模型或代码修正。统一环境、初态、训练量和随机种子，是为了公平比较；学习率、批量、探索噪声与观测处理等参数则根据单种子预实验调整，以缓解训练振荡和探索不足 [5, 2]。同一算法及其 CBF 版本采用相同调整，完整参数见附录 D.1。

E.2 车辆跟随

论文图 5 与附录 B 考察五车直线跟随，仅控制第 4 辆车的输入 u。其连续动力学为 $\dot p_4 = v_4$、$\dot v_4 = -k_d v_4 + u$，$k_d = 0.1$；仿真采样周期为 0.05 s，并在加速度中加入高斯噪声。其余驾驶员以 30 m/s 为目标车速，并按论文式 (27) 制动：车 2、3 响应各自前车的 6 m 车距，车 5 响应与车 3 的 12 m 车距。真实参数为 $k_p = 4$、$k_b = 20$，名义值为 $k_d = 0$、$k_p = 3.5$、$k_b = 18$，输入限幅为 $\pm 100\,\mathrm{m/s^2}$。

记第 4 辆车的实际加速度为 a_4，前、后车距为 $d_f = p_3 - p_4$、$d_r = p_4 - p_5$。按论文式 (19)，回合回报为

$$R = -\sum_t \left[v_{4,t} \max(u_t, 0) + \sum_{d \in \{d_{f,t}, d_{r,t}\}} \frac{500}{|d|} \mathbf{1}_{\{d \le 3\}} \right].$$

燃油项使用动力学中的输入 u，3 m 内的近距项为软惩罚，CBF 的安全车距则为 2 m。修改后改用实际正加速度计算燃油惩罚，并调整环境与终止规则，具体对照见表 E.2。

主要检验论文图 5 的结论：CBF 版本全程无碰撞，TRPO、DDPG 在训练后期仍频繁碰撞；TRPO-CBF 学得更快、回报高于 TRPO，DDPG-CBF 回报高于 DDPG，但两种 DDPG 均未学到高性能策略。论文曲线展示 600 回合，未注明每回合步数。

表 E.2 车辆跟随主要设置：作者源码默认值与修改后设置（算法超参数见附录表 D.2）

项目	作者源码默认	修改后设置
环境	四份仿真器；车 1、2、3、5 的噪声标准差 5（TRPO 类）、10（DDPG）或 0（DDPG-CBF），车 4 无噪声；不截断加速度输入	共用一个仿真器；五辆车噪声标准差均为 1；加速度输入截断到 ± 100
回合与初态	80 步（4 s）；间距 6 m、速度 30 m/s 固定	200 步（10 s）；间距 6 ± 0.5 m、速度 30 ± 1 m/s 均匀随机
奖励与终止	燃油项用指令 u；$\lvert 500/d \rvert$（$d < 2.99$）；碰撞后继续至回合结束	燃油项用实际正加速度 $\max(a_4, 0)$；$500/\max(d, 0.5)$（$d \le 3$）；碰撞即终止，惩罚为 $500 + 100\times$ 剩余步数
训练量与种子	TRPO 1.8×10^6 步，TRPO-CBF 1.2×10^6 步，DDPG 两种各 1000 个回合；TRPO 类无种子参数	每种 3×10^5 步，种子 1–3；CBF 版本另用 400 步标定 GP
观测	15 维绝对状态	10 维缩放特征，不含其他车的加速度

表 E.2 前三行属于环境与任务设置调整，不属于代码错误修正。共用仿真器、统一噪声，是为了让四种算法在相同条件下比较；延长回合并随机化初态，使训练覆盖更长的跟随过程和更多初始状态。碰撞后立即终止并给予惩罚，使碰撞成为明确的失败事件；燃油惩罚则由控制指令改为按实际正加速度计算。这些调整改变了任务与奖励，因此回报只在各自设置内比较，作者源码与修改后代码之间仅对照碰撞和 2 m 越界情况。CBF 版本在训练前额外采集 400 步数据，用于拟合初始 GP 残差模型；其余超参数调整在同一算法及其 CBF 版本中保持一致。